

Estatística Aplicada à Epidemiologia II

Introdução à modelagem estatística

Leo Bastos – leonardo.bastos@fiocruz.br

PROCC – Fundação Oswaldo Cruz

- Principais distribuições de probabilidade
- Teorema central do Limite
- Inferência (frequentista e bayesiana*)

- Normal $X \sim N(\mu, \sigma^2)$

$$f(x \mid \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x-\mu)^2}, \quad x \in \mathbb{R}, \mu \in \mathbb{R}, \sigma^2 > 0.$$

Se $X \sim N(\mu, \sigma^2)$ então $Z = \frac{(X-\mu)}{\sigma} \sim N(0, 1)$

- Bernoulli ($X \sim \text{Bernoulli}(\theta)$)

$$P(X = x) = \theta^x(1 - \theta)^{1-x}, \quad x = \{0, 1\}, \theta \in (0, 1).$$

- Binomial ($X \sim \text{Bin}(n, \theta)$)

$$P(X = x) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}, \quad x = 0, 1, \dots, n \in \mathbb{N}, \theta \in (0, 1).$$

Distribuições derivadas da Normal

Seja $X_1, X_2, \dots, X_n$ amostra aleatória da $N(\mu, \sigma^2)$

- t de Student

$$T = \frac{\bar{X}_n - \mu}{\hat{\sigma}^2 / \sqrt{n}} \sim t_{n-1}, \quad \hat{\sigma}^2 = \frac{1}{n-1} \sum_i (X_i - \bar{X}_n)^2$$

- Qui-quadrado

$$W_n = \sum_{i=1}^n Z_i^2 \sim \chi_n^2, \quad Z_i \perp Z_j, \quad \forall i \neq j$$

- Distribuição F

$$F = \frac{W_n/n}{W_m/m} \sim F_{n,m}, \quad W_n \perp W_m$$

Teorema (TCL)

Seja $Y_1, Y_2, Y_3, \dots$ uma sequência de variáveis aleatórias independentes identicamente distribuídas (amostra aleatória) com média $\mathbb{E}[Y_i] = \mu < \infty$ e variância $\mathbb{V}[Y_i] < \infty$. A medida que n cresce, a distribuição da média amostral $\bar{Y}_n = \frac{1}{n} \sum_{i=1}^n Y_i$ aproxima-se da distribuição Normal com média μ e variância σ^2/n , ou seja

$$\bar{Y}_n \xrightarrow{d} N(\mu, \sigma^2/n)$$

- É um resultado muito poderoso, e essa aproximação já costuma ser boa com valores “baixos” de n (10000, 1000, as vezes 100 ou menos)
- Existem outras versões do TCL, e.g. Erdős and Renyi (1959) provam uma versão do TCL para amostras sem reposição.

- Inferência baseada na verossimilhança

$$L(\theta) = \prod_{i=1}^n f(y_i | \theta)$$

- Estimador de máxima verossimilhança

$$\hat{\theta} = \arg \max_{\theta \in \Theta} L(\theta)$$

- Invariância: Se $\hat{\theta}$ é um EMV para θ , então $h(\hat{\theta})$ é um EMV para $h(\theta)$
- Distribuição assintótica de um EMV

$$\hat{\theta} \xrightarrow{d} N(\theta, \mathbb{V}(\hat{\theta}))$$

- Problema: Encontrar o EMV e sua variância

- Intervalo de confiança de $(1 - \alpha) \times 100\%$ de um EMV

$$[\hat{\theta} \pm z_{1-\alpha/2} \sqrt{\mathbb{V}(\hat{\theta})}]$$

- Teste de Wald de tamanho α para as hipótese $H_0 : \theta = \theta_0$ versus $H_a : \theta \neq \theta_0$

Rejeita-se H_0 se $Z = \frac{|\hat{\theta} - \theta_0|}{\sqrt{\mathbb{V}(\hat{\theta})}} > z_{1-\alpha/2}$

- Valor-p:

$$\text{valor-p} = 2P \left(Z > \frac{|\hat{\theta} - \theta_0|}{\sqrt{\mathbb{V}(\hat{\theta})}} \right)$$

Rejeita-se H_0 se $\text{valor-p} < \alpha$.

- Definição subjetiva de probabilidade, tudo que é desconhecido pode ser representado por uma distribuição de probabilidades
 - Priori: $p(\theta)$ (Conhecimento prévio a respeito de um parâmetro)
 - Verossimilhança: $L(\theta) = p(y_1, \dots, y_n | \theta)$ (Distribuição dos dados condicional ao parâmetro desconhecido)
 - Posteriori: $p(\theta | y_1, \dots, y_n)$ (Conhecimento atualizado a respeito de um parâmetro a luz aos dados)

$$p(\theta | y_1, \dots, y_n) = \frac{p(\theta)L(\theta)}{\int p(\theta)L(\theta)d\theta}$$

- Problema: Resolver a integral do denominador! (Métodos numéricos)

Exemplo: Distribuição Bernoulli

Seja $Y_1, Y_2, \dots, Y_n$ amostra aleatória de uma Bernoulli(θ)

- O que é um modelo estatístico?
 - É uma representação matemática da relação entre uma variável **resposta**, e uma ou mais variáveis **explicativas**.
- Variável resposta:
É o **desfecho** de interesse, usualmente denotado pela letra Y .
- Variáveis explicativas:
É a variável de **exposição**, que pode ser mais de uma, e as variáveis de **controle**, usualmente denotadas pela letra X .

- No problema onde se queira encontrar a relação entre o número de cigarros consumidos por um fumante, e a quantidade de nicotina no sangue de seu(sua) companheiro(a) não fumante.
- Quem é o desfecho e quem é a exposição?

- Muitos modelos tem a seguinte forma simplificada:

$$Y = f(X) + \epsilon,$$

- $f(X)$ é a componente sistemática
 - ϵ é o erro aleatório
- A componente sistemática é uma função matemática das variáveis explicativas.
- O primeiro objetivo da modelagem estatística é estimar o componente sistemático.
- Isso é alcançado analisando dados de vários indivíduos (no exemplo, vários casais com um parceiro fumante e outro não fumante)

- Após estimarmos o componente sistemático, temos os chamados valores **ajustados**, denotados por $\hat{Y}$, ou seja,

$$Y = \hat{Y} + \epsilon.$$

- Os valores ajustados permitem que façamos afirmações epidemiológicas sobre uma aparente relação entre o desfecho Y e as variáveis explicativas X .
- No exemplo, podemos dizer qual a quantidade esperada de nicotina no sangue para qualquer quantidade de cigarros fumados pelo seu(sua) parceiro(a).
- Essa 'previsão' claramente é imperfeita, e essa variação entre o esperado e o observado é dada pela aleatoriedade.

- É extremamente importante que o que 'sobra' para o erro aleatório seja realmente aleatório.
- Que não tenha nenhum outro componente sistemático que possa ser removido ou incorporado ao valor ajustado $\hat{Y}$.
- No exemplo, a quantidade de nicotina no sangue de um conjugê não fumante com um companheiro fumante depende **somente** do número de cigarros que o companheiro fuma?

- Como definir o componente sistemático? Qual a função matemática mais simples que poderíamos usar?
- O que poderíamos assumir para o componente aleatório?
 - Qual o valor médio poderíamos esperar?
 - Como esses valores poderiam estar distribuídos?
- E quanto aos dados? Será que temos que considerar algo ao coletar os dados?

Modelagem estatística, de uma forma mais geral

- Defina seu desfecho, Y , entenda bem sua natureza.
 - Y é a quantidade de nicotina no sangue do parceiro não fumante.
- Represente a aleatoriedade associada ao desfecho usando uma distribuição de probabilidades.
 - $Y \sim N(\mu, \sigma^2)$
- Defina o valor médio do desfecho como uma função que dependa da exposição e potencialmente de outras variáveis de controle.
 - $\mu = \alpha + \beta X$
- Isso é equivalente a: $Y = \alpha + X\beta + \epsilon, \epsilon \sim N(0, \sigma^2)$

- OK, mas quais são os valores de $(\alpha, \beta, \sigma^2)$?
- Precisamos agora de uma amostra de tamanho n com observações **independentes** da população de interesse (casais na qual apenas uma das pessoas fuma).
- De posse dessa amostra, denotada por $(Y_1, X_1), (Y_2, X_2), (Y_3, X_3), \dots, (Y_n, X_n)$, estimamos $(\alpha, \beta, \sigma^2)$.
- Como?

- Usando a distribuição de probabilidades assumida para Y , e a **indepedência** entre as observações construímos o que chamamos de verossimilhança:

$$L(\alpha, \beta, \sigma^2) = \prod_{i=1}^n d\text{norm}(y_i, \alpha + x_i\beta, \sigma)$$

- A partir dessa função, estimamos os parâmetros $(\alpha, \beta, \sigma^2)$ basicamente segundo duas abordagens:
 - Abordagem frequentista: maximizando $L(\alpha, \beta, \sigma^2)$
 - Abordagem bayesiana: obtendo a posteriori de $(\alpha, \beta, \sigma^2)$
- Em ambas abordagens temos estimativas pontuais e intervalares para $(\alpha, \beta, \sigma^2)$

Nas próximas sessões vamos estudar

- O modelo linear na sua forma $Y = \alpha + X\beta + e$
- Diferentes tipos de variáveis de exposição (x)
- Inferência sob as abordagens frequentista e bayesiana*.