

Estatística aplicada à epidemiologia II

Modelos para desfecho contínuo

Leo Bastos – leonardo.bastos@fiocruz.br

PROCC – Fundação Oswaldo Cruz

Modelagem estatística, de uma forma mais geral

- Defina seu desfecho, Y , entenda bem sua natureza.
- Represente a aleatoriedade associada ao desfecho usando uma distribuição de probabilidades. (Componente aleatório / Verossimilhança)
- Defina uma variável de exposição, X , e sua relação com a média do desfecho (Componente sistemático)

$$\mathbb{E}[Y] = f(X)$$

- Estime os parâmetros associados (Inferência)

Desfecho contínuo exposição categórica


- Vamos supor que temos um desfecho contínuo, Y , e uma variável categórica com I categorias
- Se fossem duas categorias, $I = 2$, teríamos um teste de comparação de médias. (Qual teste?)
- Para $I > 2$ categorias, podemos usar uma técnica chamada **ANOVA** (**AN**alysis **Of** **VA**riance)
- ANOVA é uma técnica estatística proposta por Sir Ronald A. Fisher (1921)
- E consiste é um método de testar a hipótese de igualdade de médias em diferentes grupos

Exemplo: ANOVA

- Suponha que um estudo de efeitos de dieta restrita em carne tenha 6 veganos, 6 lacto-vegetarianos, e 6 onívoros (sem restrição de dieta). E o nível de colesterol (mmol/l) foi avaliado.
- Os dados estão na tabela abaixo:

	Onívoros	Vegetarianos	Veganos
1	6.35	5.92	6.01
2	6.47	6.03	5.42
3	6.09	5.81	5.44
4	6.37	6.07	5.82
5	6.11	5.73	5.73
6	6.50	6.11	5.62

Exemplo



- De forma geral, na ANOVA queremos testar a seguinte hipótese:

$$H_0 : \mu_1 = \mu_2 = \cdots = \mu_I$$

$$H_1 : \mu_i \neq \mu_j \text{ para algum } i \text{ e } j.$$

- Construindo a ANOVA

- Seja y_{ij} o valor do desfecho para a j -ésima observação do grupo i .
- Mantra da ANOVA

$$\text{Soma de quadrados total} = \text{Soma de quadrados entre grupos} + \text{Soma de quadrados dentro dos grupos}$$

- Em matemáticas

$$\sum_i \sum_j (y_{ij} - \bar{y})^2 = \sum_i n_i (\bar{y}_i - \bar{y})^2 + \sum_i \sum_j (y_{ij} - \bar{y}_i)^2$$

$$SQ_t = SQ_e + SQ_d$$

- A famosa tabela da ANOVA

Fonte de variação	Soma de Quad.	g.l.	MS	F
Entre	SQ_e	$l - 1$	$s_e^2 = \frac{SQ_e}{l - 1}$	$F = \frac{s_e^2}{s_d^2}$
Dentro	SQ_d	$n - l$	$s_d^2 = \frac{SQ_d}{n - l}$	
Total	SQ_t	$n - 1$		

- Sob H_0 (médias iguais), $F \sim F_{(l-1, n-l)}$.
- Esse resultado é válido se:
 - as variâncias dos grupos pode ser considerada a mesma
 - o desfecho segue uma distribuição normal, OU se a amostra é grande o suficiente para usar o TCL.

Teorema central do limite

Esse teorema (e suas variações) tem papel fundamental na inferência estatística, e estabelece que:

Theorem (TCL)

Seja $Y_1, Y_2, Y_3, \dots$ uma sequência de variáveis aleatórias independentes identicamente distribuídas com média $\mathbb{E}[Y_i] = \mu$ e variância $\mathbb{V}[Y_i] < \infty$. Então quando n se aproxima do infinito,

$$\sqrt{n}(\bar{Y}_n - \mu) \xrightarrow{d} N(0, \sigma^2).$$

- Descritivas

	Dieta	n	Media	Variancia
1	Onívoros	6	6.31	0.03
2	Vegetarianos	6	5.95	0.02
3	Veganos	6	5.67	0.05

- No R

```
> aov(Colesterol ~ Dieta, dados)
```

ANOVA no exemplo

- Saída editada

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Dieta	2	1.24	0.62	17.62	0.0001
Residuals	15	0.53	0.04		

- Qual a conclusão?

- Como o teste F da ANOVA foi significativo, então temos que encontrar qual(is) grupo(s) tem a média diferente dos outros.
- Isso é feito fazendo comparações dois a dois, lembrando que a variância é a mesma (por hipótese) e há correção para comparações múltiplas.

Comparações múltiplas

```
> pairwise.t.test(x = dados$Colesterol,  
+                 g = dados$Dieta)
```

Pairwise comparisons using t tests with pooled SD

data: dados\$Colesterol and dados\$Dieta

	Onívoros	Vegetarianos
Vegetarianos	0.0078	-
Veganos	8.5e-05	0.0243

P value adjustment method: holm

- A suposição de normalidade ou que o tamanho da amostra seja grande o suficiente podem ser inapropriadas.
- Uma alternativa é o uso de testes não-paramétricos (teste que não assumem uma distribuição de probabilidade para o desfecho).
- A versão não-paramétrica do test-t é o teste de Wilcoxon.
- A ANOVA tem sua versão não-paramétrica é chamada de teste Kruskal-Wallis. (seção 9.12, Woodward)

- Esse teste tem como hipóteses

H_0 : As distribuições de probabilidade dos diferentes grupos é a mesma;

H_1 : a distribuição de algum grupo é diferente do demais.

- Esse teste é baseado nos postos (rank) dos dados.

Teste Kruskal-Wallis (intuição)

Dados observados:

	Onívoros	Vegetarianos	Veganos
1	6.35	5.92	6.01
2	6.47	6.03	5.42
3	6.09	5.81	5.44
4	6.37	6.07	5.82
5	6.11	5.73	5.73
6	6.50	6.11	5.62

Teste Kruskal-Wallis (intuição)

Posto dos dados:

	Onívoros	Vegetarianos	Veganos
1	15.00	8.00	9.00
2	17.00	10.00	1.00
3	12.00	6.00	2.00
4	16.00	11.00	7.00
5	13.50	4.50	4.50
6	18.00	13.50	3.00


```
> kruskal.test(Colesterol ~ Dieta, data = dados)
```

Kruskal-Wallis rank sum test

data: Colesterol by Dieta

Kruskal-Wallis chi-squared = 12.52, df = 2, p-value = 0.001911

Comparações múltiplas

```
> pairwise.wilcox.test(x = dados$Colesterol,  
+                       g = dados$Dieta)
```

Pairwise comparisons using Wilcoxon rank sum test with
data: dados\$Colesterol and dados\$Dieta

	Onívoros	Vegetarianos
Vegetarianos	0.0205	-
Veganos	0.0065	0.0542

P value adjustment method: holm

Variável dummy

- Variáveis categóricas podem ser representadas por variáveis indicadoras ou dummy.
- Uma variável categórica com I categorias pode ser representada com I variáveis dummy, uma por categoria.
- No exemplo, portanto teremos portanto 3 variáveis dummy:

$$x^{(1)} = \begin{cases} 1 & \text{para onívoros} \\ 0 & \text{caso contrário} \end{cases},$$

$$x^{(2)} = \begin{cases} 1 & \text{para vegetarianos} \\ 0 & \text{caso contrário} \end{cases},$$

$$x^{(3)} = \begin{cases} 1 & \text{para veganos} \\ 0 & \text{caso contrário} \end{cases}.$$

O modelo da ANOVA

- Para evitar problemas numéricos (identificabilidade), uma variável com I categorias deve ter $I - 1$ variáveis dummy.
- Uma das categorias deve ser escolhida como base.
(Na epidemiologia, usa-se a categoria de menor ou maior risco)
- No exemplo, suponha que escolhemos os onívoros como categoria de base, então temos agora as seguintes combinações:

Dieta	$X^{(2)}$	$X^{(3)}$
Onívoro	0	0
Vegetariano	0	1
Vegano	1	0

O modelo da ANOVA

- De forma geral, o modelo estatístico que gere resultados equivalentes a ANOVA é

$$y = \alpha + x^{(2)}\beta_2 + x^{(3)}\beta_3 + \cdots + x^{(I)}\beta_I + \epsilon$$

onde $\epsilon \sim N(0, \sigma^2)$.

- Notem que não tem a variável dummy da primeira categoria (que é escolhida arbitrariamente).
- No exemplo, temos agora as médias

Dieta	$X^{(2)}$	$X^{(3)}$	Média
Onívoro	0	0	α
Vegetariano	0	1	$\alpha + \beta_2$
Vegano	1	0	$\alpha + \beta_3$

- Usualmente não a necessidade de criar variáveis dummy, elas são criadas automaticamente nos softwares.
- Diferentes softwares usam diferentes formas para escolha da categoria de base. No R, isso é feito automaticamente ao definir uma variável como fator.

```
> # O primeiro valor do vetor levels é a referencia  
> # default: ordem alfabetica  
> factor(x, levels)  
> #  
> # Redefinindo a categoria de referencia  
> relevel(x, ref)
```

- A análise de variância foi uma técnica de alta relevância no milênio passado.
- Houve muito desenvolvimento em torno dessa técnica, como a Two way ANOVA, Three Way ANOVA, MANOVA, etc.
- Por outro lado, a ANOVA e sua versão não paramétrica (Kruskall-Wallis) são bastante usadas na epidemiologia como medida descritiva.
- Útil por exemplo, na “tabela 1” (ou “tabela 2”) quando há cruzamento entre uma variável categórica versus uma contínua.
- Como a ANOVA pode ser escrita como um modelo linear, vamos olhar para essa modelagem a partir de agora.

Modelagem estatística, de uma forma mais geral

- Defina seu desfecho, Y , entenda bem sua natureza.
- Represente a aleatoriedade associada ao desfecho usando uma distribuição de probabilidades. (Componente aleatório / Verossimilhança)
- Defina uma variável de exposição, X , e sua relação com a média do desfecho (Componente sistemático)

$$\mathbb{E}[Y] = f(X; \theta)$$

- Estime os parâmetros θ (Inferência)

- Modelo linear simples

$$Y = \alpha + \beta X + \epsilon,$$

onde $\epsilon \sim N(0, \sigma^2)$.

- O modelo linear é um dos modelos mais úteis da estatística, e é aplicado em praticamente todas as áreas do conhecimento.
- Também conhecido por regressão linear, o termo regressão foi proposto por Francis Galton em 1886 em seu estudo de eugenia. (Vejam um pouco mais sobre isso em <http://chance.amstat.org/2013/09/1-pagano/>)
- É possível construir uma tabela ANOVA para desfecho e exposição contínuas.


- Modelo linear simples

$$Y = \alpha + \beta X + \epsilon,$$

onde $\epsilon \sim N(0, \sigma^2)$.

- α é usualmente chamado de intercepto, pois é o valor de y quando $x = 0$.
- β é chamado de coeficiente de inclinação (slope), ele representa a contribuição em y quando x aumenta em um unidade.
- σ^2 representa a variabilidade associada aos erros quando uma reta é ajustada.


Grafico de dispersão



Exemplo: DMFT versus consumo de açúcar

- Esse exemplo considera a relação entre o consumo de açúcar e cáries em 61 países em desenvolvimento. Dados explorados em Woodward and Walker (1994).
- DMFT (Decayed, missing, or filled teeth) é um valor médio de DMFT em crianças de 12 anos por país, extraído do *WHO Oral Disease Data Bank*.
- Consumo de açúcar (Kg per capita/ano) foi derivado de fontes dos governos e indústrias desses países.

Exemplo: DMFT versus consumo de açúcar



- Modelo linear simples

$$Y = \alpha + \beta X + \epsilon,$$

onde $\epsilon \sim N(0, \sigma^2)$.

- O método mais antigo para estimar (α, β) é o método de mínimos quadrados (OLS) que tem a seguinte formulação matemática:

$$(\hat{\alpha}, \hat{\beta})_{OLS} : \arg \min \sum_i (y_i - \alpha - \beta x_i)^2$$

- O estimador de máxima verossimilhança é para $(\alpha, \beta, \sigma^2)$ é dado por

$$(\hat{\alpha}, \hat{\beta}, \hat{\sigma}^2)_{MLE} : \arg \max (\sigma^2)^{-\frac{n}{2}} \exp \left\{ -\frac{1}{2\sigma^2} \sum_i (y_i - \alpha - \beta x_i)^2 \right\}$$

Exemplo: DMFT versus consumo de açúcar

```
> output <- lm(DMFT ~ Consumo, data = dmft2)
> output
```


Call:

```
lm(formula = DMFT ~ Consumo, data = dmft2)
```

Coefficients:

(Intercept)	Consumo
1.16468	0.04698

Exemplo: DMFT versus consumo de açúcar



- Vantagem do MLE, seja $\hat{\theta}$ um MLE para θ , então:

$$\hat{\theta} \xrightarrow{d} N(\theta, \mathbb{V}[\hat{\theta}])$$

- Suposição de independência, e normalidade de Y ou grandes amostras.
- Isso permite a construção de ICs e a realização de testes de hipóteses.
- PRO: Contas já feitas e implementadas para modelos lineares em qualquer software estatístico com alguma dignidade.
- CON: Suposições (Independência, normalidade e homocedasticidade*) usualmente muito fortes.

- Assumindo resposta normal, temos que:

$$\hat{\alpha} \sim N(\alpha, \mathbb{V}[\hat{\alpha}]) \quad \text{e} \quad \hat{\beta} \sim N(\beta, \mathbb{V}[\hat{\beta}])$$

- Permitindo testar $H_0 : \beta = 0$ versus $H_A : \beta \neq 0$ com um teste-t, isto é
 - Rejeita-se H_0 se $T > t_{n-1, 1-\alpha/2}$ onde

$$T = \frac{\hat{\beta}}{\sqrt{\widehat{\mathbb{V}}[\hat{\beta}]}}$$

- Rejeita-se H_0 se valor-p = $P(T > T_{obs} \mid \beta = 0) < \alpha$, onde α é o nível de significância do teste. Usualmente 5%.
- Analogamente pode-se fazer inferência para o intercepto α .

Saida completa

```
> summary(output)
```

Call:

```
lm(formula = DMFT ~ Consumo, data = dmft2)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-2.3370	-0.8124	-0.2896	0.4381	5.2771

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	1.16468	0.32044	3.635	0.000585	***
Consumo	0.04698	0.01082	4.340	5.66e-05	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.394 on 59 degrees of freedom

Multiple R-squared: 0.242, Adjusted R-squared: 0.2292

F-statistic: 18.84 on 1 and 59 DF, p-value: 5.662e-05

Coeficiente de determinação (R^2)

- O coeficiente de determinação (R^2) mostra a proporção da variação da resposta (desfecho) atribuída à variável independente (exposição).
- O R^2 é dado por

$$R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

onde $0 < R^2 < 1$.

- $R^2 = 1$ significa que a exposição explica toda variação do desfecho.
- O modelo linear simples está relacionado com a correlação de Pearson

$$\rho(Y, X)^2 = R^2$$

- Qual seria o valor esperado de DMFT para um país em desenvolvimento não observado cujo consumo de açúcar foi de 50 kg per capita/ano?
- Podemos prever o valor médio esperado do DMFT para qualquer valor de consumo de açúcar usando a equação:

$$\hat{\mathbb{E}}[\text{DMFT}^{(n)} \mid \text{Consumo}^{(n)}] = \hat{\alpha} + \hat{\beta}\text{Consumo}^{(n)}$$

- Ou seja,

$$\hat{\mathbb{E}}[\text{DMFT}^{(n)} \mid \text{Consumo}^{(n)} = 50] = 1.165 + 0.047 \times 50 = 3.515$$

- Podemos prever o valor médio de Y para qualquer valor de X usando a equação

$$\hat{\mathbb{E}}[Y^{(novo)}] = \hat{\alpha} + \hat{\beta}X^*$$

- Por exemplo, e se consumo de açúcar nesse país fosse reduzido pela metade, ou seja de 50 para 25 kg per capita/ano. Qual seria o DMFT esperado?

$$\hat{\mathbb{E}}[\text{DMFT}^{(novo)} \mid \text{Consumo}^* = 25.0] = 1.165 + 0.047 \times 25.0 = 2.34$$

- E a incerteza dessas previsões?

- Usando outro resultado dos EMVs, temos que a distribuição de $\widehat{\mathbb{E}[Y^{(novo)}]}$ é dada por

$$\widehat{\mathbb{E}[Y^*]} \sim N(\alpha + \beta X^*, \mathbb{V}[\widehat{\mathbb{E}[Y^*]}])$$

- A variância de $\widehat{\mathbb{E}[Y^*]}$ tem a seguinte forma:

$$\begin{aligned}\mathbb{V}[\widehat{\mathbb{E}[Y^*]}] &= \mathbb{V}[\hat{\alpha} + \hat{\beta}X^*] \\ &= \mathbb{V}[\hat{\alpha}] + (X^*)^2\mathbb{V}[\hat{\beta}] + 2X^*\text{Cov}[\hat{\alpha}, \hat{\beta}]\end{aligned}$$

- A matriz de covariância dos coeficientes de um modelo linear é calculada ao ajustar um modelo no R, e dada pela função `vcov(modelo)`


Variância da previsão

```
> (COV <- vcov(output))  
  
              (Intercept)      Consumo  
(Intercept)  0.102681069 -0.0028804239  
Consumo      -0.002880424  0.0001171536  
  
> #  
  
> # A variancia da previsao para o valor esperado  
> COV[1,1] + 50^2*COV[2,2] + 2*50*COV[1,2]  
[1] 0.1075228  
  
> #  
  
> # Variancia para o cenário de redução de consumo  
> COV[1,1] + 25^2*COV[2,2] + 2*25*COV[1,2]  
[1] 0.0318809
```


Variância do valor esperado

```
> # Usando a funcao predict
> previsao <- predict(output, se.fit = T,
+                      newdata = data.frame(
+                        Consumo = c(50, 25)
+                      )
+                      )
> previsao$se.fit^2
      1      2
0.1075228 0.0318809
```

Exemplo: DMFT versus consumo de açúcar




Voltando no exemplo da ANOVA: Efeito da dieta

- Suponha que um estudo de efeitos de dieta restrita em carne tenha 6 veganos, 6 lacto-vegetarianos, e 6 onívoros (sem restrição de dieta). E o nível de colesterol (mmol/l) foi avaliado.
- Os dados estão na tabela abaixo:

	Onívoros	Vegetarianos	Veganos
1	6.35	5.92	6.01
2	6.47	6.03	5.42
3	6.09	5.81	5.44
4	6.37	6.07	5.82
5	6.11	5.73	5.73
6	6.50	6.11	5.62

Box plot: Efeito da dieta



Modelo linear para o efeito da dieta

- O modelo para explicar o nível de colesterol (mmol/l) segundo a dieta é dado por

$$\text{colesterol} = \alpha + \text{Dieta}_2\beta_1 + \text{Dieta}_3\beta_2 + \epsilon$$

onde $\epsilon \sim N(0, \sigma^2)$.

- Lembrando que

Dieta	Dieta ₂	Dieta ₃	Média
Onívoro	0	0	α
Vegetariano	0	1	$\alpha + \beta_1$
Vegano	1	0	$\alpha + \beta_2$

Exemplo: Efeito da dieta

```
> output_dieta <- lm(Colesterol ~ Dieta, data = dados)
> output_dieta
```

Call:

```
lm(formula = Colesterol ~ Dieta, data = dados)
```

Coefficients:

(Intercept)	DietaVegetarianos	DietaVeganos
6.3150	-0.3700	-0.6417

Exemplo: Efeito da dieta

```
> summary(output_dieta)
```

Call:

```
lm(formula = Colesterol ~ Dieta, data = dados)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-0.2533	-0.1875	0.0450	0.1412	0.3367

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	6.31500	0.07673	82.305	< 2e-16 ***
DietaVegetarianos	-0.37000	0.10851	-3.410	0.00388 **
DietaVeganos	-0.64167	0.10851	-5.914	2.85e-05 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.1879 on 15 degrees of freedom

Multiple R-squared: 0.7015, Adjusted R-squared: 0.6616

F-statistic: 17.62 on 2 and 15 DF, p-value: 0.0001155