

Estatística aplicada à epidemiologia II

Modelos para desfecho contínuo

Leo Bastos – leonardo.bastos@fiocruz.br

PROCC – Fundação Oswaldo Cruz

<https://github.com/lsbastos/eae2>

- Vimos métodos para associar um desfecho contínuo, Y , e uma exposição X (categórica e também contínua)
 - X for categórica: ANOVA (teste Kruskal-Wallis) e teste-t (teste Wilcoxon) para comparações múltiplas
 - Vimos que a ANOVA é um caso particular do modelo linear simples
- X contínua: Definimos o modelo linear simples

$$Y_i = \alpha + \beta X_i + e_i, \quad e_i \sim N(0, \sigma^2) \quad e_i \perp e_j, i \neq j$$

- Estimação e inferência

$$\hat{\alpha} \sim N(\alpha, \mathbb{V}[\hat{\alpha}]) \quad \text{e} \quad \hat{\beta} \sim N(\beta, \mathbb{V}[\hat{\beta}])$$

- Coeficiente de determinação (R^2)

O modelo linear múltiplo

- Vamos assumir que temos duas ou mais variáveis explicativas.
- Seja Y um desfecho contínuo avaliado em n observações independentes, e de forma geral p variáveis explicativas X , ou seja,

$$Y_i | X_i \sim N(\mu_i, \sigma^2), \quad i = 1, 2, \dots, n,$$
$$\mu_i = \alpha + \beta_1 X_{1,i} + \beta_2 X_{2,i} + \dots + \beta_p X_{p,i}.$$

- Isso é o mesmo que escrever

$$Y_i = \alpha + \beta_1 X_{1,i} + \beta_2 X_{2,i} + \dots + \beta_p X_{p,i} + \epsilon_i$$

onde $\epsilon_i \sim N(0, \sigma^2)$, e $\epsilon_i \perp \epsilon_j, \forall i \neq j$.

- Forma matricial

$$Y = X\beta + e \quad e \sim N_n(0, \sigma^2 I_n)$$

onde Y é um vetor $(n \times 1)$, X é uma matriz $(n \times (p + 1))$, $\beta = (\alpha, \beta_1, \dots, \beta_p)^T$, $\sigma^2 > 0$ e I_n é matriz identidade de ordem n .

- Estimador de mínimos quadrados (e EMV) para β

$$\hat{\beta} = (X^T X)^{-1} X^T Y$$

- $\hat{\beta}$ segue uma normal $(p + 1)$ -variada

$$\mathbb{E}[\hat{\beta}] = \beta \quad \mathbb{V}[\hat{\beta}] = \sigma^2 (X^T X)^{-1}$$


Exemplo: Eficiência de ração do ganho de peso de ratos

- Considere um estudo realizado para avaliar a eficiência de ração no ganho de peso de ratos.
- Seja Y peso (em g) de 45 ratos com 20 dias de idade alimentados a partir do desmame por duas semanas com uma das três marcas diferentes de ração.
- Os ratos também pertencem a 3 linhagens distintas.

```
> summary(racao)
```

ID	Linhagem	Racao	Peso
Min. : 1	Swiss :27	Controle:15	Min. : 8.64
1st Qu.:12	129 PAS: 9	NovaIr :15	1st Qu.:16.44
Median :23	ALOX 5 : 9	NovaAuto:15	Median :27.20
Mean :23			Mean :23.98
3rd Qu.:34			3rd Qu.:30.30
Max. :45			Max. :37.80
			NA's :1

Visualizando os dados




```
> summary(aov(Peso ~ Racao, data = racao))
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Racao	2	394	196.99	3.066	0.0574 .
Residuals	41	2634	64.25		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

1 observation deleted due to missingness

Visualizando os dados




```
> summary(aov(Peso ~ Linhagem, data = racao))
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Linhagem	2	2531.1	1265.5	104.3	<2e-16 ***
Residuals	41	497.4	12.1		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
1 observation deleted due to missingness

Visualizando os dados



- O modelo que incorpora a exposição e controla pela linhagem é dado por

$$Y_i \sim N(\mu_i, \sigma^2), \quad i = 1, 2, \dots, 45,$$
$$\mu_i = \alpha + \beta_2 X_{1,i}^{(NovaAu)} + \beta_3 X_{1,i}^{(Novalr)} + \beta_3 X_{2,i}^{(ALOX5)} + \beta_2 X_{2,i}^{(Swiss)}$$

onde X_1 é o efeito da ração, e X_2 é o efeito da linhagem.

- A notação no R seria: *Peso* ~ *Racao* + *Linhagem*

Two-way ANOVA

```
> summary(aov(Peso ~ Racao + Linhagem, data = racao))
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Racao	2	394.0	197.0	54.19	5.51e-12 ***
Linhagem	2	2492.7	1246.3	342.87	< 2e-16 ***
Residuals	39	141.8	3.6		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

1 observation deleted due to missingness

O modelo linear no R

```
> modelo <- lm(Peso ~ Racao + Linhagem, data = racao)
> summary(modelo)
```

Call:

```
lm(formula = Peso ~ Racao + Linhagem, data = racao)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-4.0292	-1.3412	0.1531	1.4275	3.7783

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	34.0217	0.5450	62.422	< 2e-16 ***
RacaoNovaIr	-4.8073	0.6962	-6.905	2.89e-08 ***
RacaoNovaAuto	-6.7749	0.7087	-9.560	9.02e-12 ***
Linhagem129 PAS	-14.5277	0.7375	-19.698	< 2e-16 ***
LinhagemALOX 5	-16.0377	0.7375	-21.745	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.907 on 39 degrees of freedom

(1 observation deleted due to missingness)

Multiple R-squared: 0.9532, Adjusted R-squared: 0.9484

F-statistic: 198.5 on 4 and 39 DF, p-value: < 2.2e-16

A partir da saída

	Estimate	Std. Error	t value	$\Pr(> t)$
(Intercept)	34.0217	0.5450	62.42	0.0000
RacaoNovalr	-4.8073	0.6962	-6.91	0.0000
RacaoNovaAuto	-6.7749	0.7087	-9.56	0.0000
Linhagem129 PAS	-14.5277	0.7375	-19.70	0.0000
LinhagemALOX 5	-16.0377	0.7375	-21.75	0.0000


Em média

- os ratos da linhagem Swiss tratados com a ração controle pesam 34g.
- as duas rações, Nova Irradiada e Nova autoclavada, reduzem o peso médio em 4.8 e 6.8g respectivamente quando comparadas ao controle.
- linhagem Swiss em média pesa 14.5g a mais que a 129 PAS, e 16g a mais que a linhagem ALOX 5.

Intervalos de confiança

```
> modelo.coef <- cbind(Est = coef(modelo), confint(modelo))
```

	Est	2.5 %	97.5 %
(Intercept)	34.02	32.92	35.12
RacaoNovalr	-4.81	-6.22	-3.40
RacaoNovaAuto	-6.77	-8.21	-5.34
Linhagem129 PAS	-14.53	-16.02	-13.04
LinhagemALOX 5	-16.04	-17.53	-14.55



- Quais forma as suposições assumidas para o modelo anterior?
 - Normalidade
 - Independência
 - Variância constante
- Será que elas são válidas?
- Como podemos checar?

- Os erros do modelo são definidos por

$$e_i = Y_i - \alpha - \sum_p X_{i,p} \beta_p$$

- O erro estimado, chamado de resíduo, é dado por

$$\hat{e}_i = Y_i - \hat{Y}_i = Y_i - \hat{\alpha} - \sum_p X_{i,p} \hat{\beta}_p$$

- Dos resíduos, no entanto, é

$$\hat{e}_i \sim N(0, \sigma^2(1 - h_{ii}))$$

onde h_{ii} é o i -ésimo elemento da diagonal da matriz H (matriz chapéu)


- Resíduos padronizados

$$r_i = \frac{\hat{e}_i}{\hat{\sigma} \sqrt{1 - h_{ii}}}$$

Suposição de normalidade


```
> hist(rstandard(modelo), col = 2)
```

Histogram of rstandard(modelo)



Suposição de normalidade

```
> qqnorm(rstandard(modelo) )  
> qqline(rstandard(modelo) )
```



Podemos testar a hipótese de normalidade usando o teste de Shapiro-Wilks


$$\begin{cases} H_0 : & \text{as observações seguem uma distribuição normal}(\mu, \sigma^2) \\ H_1 : & \text{as observações seguem outra distribuição.} \end{cases}$$

```
> shapiro.test(rstandard(modelo))  
      Shapiro-Wilk normality test  
data:  rstandard(modelo)  
W = 0.97789, p-value = 0.5514
```

Variância constante (e padrões não-lineares)

Faz-se um scatter plot dos resíduos versus a ordem dos dados, e espera-se que a variância não tenha um padrão bem definido

```
> plot(rstandard(modelo))
```



Análise de resíduos (resumo)

- A análise de resíduos consiste em um conjunto de estatísticas descritivas associadas aos resíduos de um modelo ajustado.
- A análise de resíduos deve ser realizada sempre que um modelo linear for ajustado e os coeficientes testados (teste de Wald $H_0 : \beta_k = 0$ versus $H_1 : \beta_k \neq 0$).
- As principais suposições de um modelo linear são
 - Normalidade (que pode ser relaxada se a amostra for grande)
 - Variância constante (Homocedasticidade)
 - Independência
- A análise de resíduos pode se estender ad infinitum, pois podemos testar a influência de outras variáveis, formas não lineares, presença de outlier, etc. (Ler capítulos 8 e 9 do open statistics 4th ed.)

Suponha agora que gostaríamos de ajustar diferentes modelos:

```
> modeloR <- lm(Peso ~ Racao, data = racao)
> modeloL <- lm(Peso ~ Linhagem, data = racao)
> modeloRL <- lm(Peso ~ Racao + Linhagem, data = racao)
> modeloRL2 <- lm(Peso ~ Racao * Linhagem, data = racao)
```

- Como podemos comparar diferentes modelos?
- Se os modelos forem aninhados* podemos usar a ANOVA no modelo mais completo
- Outra forma de comparar modelos é usando coeficiente de determinação e critérios de informação.

Testando a interação

No modelo mais completo temos o termo de interação *Racao : Linhagem*, podemos testar se algum dos termos da interação é significativo

```
> summary(modeloRL2)
```

Call:

```
lm(formula = Peso ~ Racao * Linhagem, data = racao)
```

Residuals:

Min	1Q	Median	3Q	Max
-3.5889	-1.2083	0.1174	1.4931	4.0111

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	33.7889	0.6178	54.695	< 2e-16 ***
RacaoNovaIr	-4.9111	0.8736	-5.621	2.44e-06 ***
RacaoNovaAuto	-5.9014	0.9005	-6.553	1.45e-07 ***
Linhagem129 PAS	-13.8022	1.2355	-11.171	4.33e-13 ***
LinhagemALOX 5	-15.5989	1.2355	-12.625	1.37e-14 ***
RacaoNovaIr:Linhagem129 PAS	0.9544	1.7473	0.546	0.5884
RacaoNovaAuto:Linhagem129 PAS	-3.2019	1.7609	-1.818	0.0776 .
RacaoNovaIr:LinhagemALOX 5	-0.4356	1.7473	-0.249	0.8046
RacaoNovaAuto:LinhagemALOX 5	-0.9519	1.7609	-0.541	0.5922

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.853 on 35 degrees of freedom



Testando a interação

Testando usando a ANOVA de modelos, partindo do modelo nulo até o modelo completo

```
> #anova(modeloRL2)
> anova(lm(Peso ~ Racao*Linhagem, data = racao))
```

Analysis of Variance Table

Response: Peso

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Racao	2	393.98	196.99	57.3526	9.006e-12 ***
Linhagem	2	2492.67	1246.33	362.8666	< 2.2e-16 ***
Racao:Linhagem	4	21.55	5.39	1.5688	0.2043
Residuals	35	120.21	3.43		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Cada linha testa a igualdade do modelo anterior (o primeiro é o modelo nulo, i.e. $Y \sim 1$) e o modelo com a adição da variável daquela linha.

Testando a interação

Note que a ordem de entrada das covariáveis do modelo é importante

```
> anova(lm(Peso ~ Linhagem*Racao, data = racao))
```

Analysis of Variance Table

Response: Peso

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Linhagem	2	2531.06	1265.53	368.4555	< 2.2e-16 ***
Racao	2	355.58	177.79	51.7637	3.502e-11 ***
Linhagem:Racao	4	21.55	5.39	1.5688	0.2043
Residuals	35	120.21	3.43		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Dica: Se for usar esse recurso, inclua a sua exposição de interesse primeiro.

Podemos comparar dois modelos

```
> anova(modeloR, modeloRL2)
```

```
Analysis of Variance Table
```

```
Model 1: Peso ~ Racao
```

```
Model 2: Peso ~ Racao * Linhagem
```

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	41	2634.43				
2	35	120.21	6	2514.2	122	< 2.2e-16 ***

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- O método da ANOVA para comparar modelos funciona bem para comparar modelos lineares alinhados
- Uma abordagem mais geral, pode usar coeficientes de determinação (R^2) e **critérios de informação**
- Os critérios de informação são construídos a partir da função de desvio (*deviance*)
- Essa função é dada por $-2 \log_e \hat{L}$, $\hat{L}$ é a verossimilhança ajustada
- Para o modelo linear a função desvio é dada por:

$$-2 \log_e \hat{L} = n \log(2\pi\hat{\sigma}^2) + \frac{1}{\hat{\sigma}^2} \sum_i (y_i - \hat{y}_i)^2$$

Coeficiente de determinação ajustado

- Vimos que o coeficiente de determinação mostra a proporção da variabilidade do desfecho que é explicada pela variabilidade das variáveis explicativas do modelo.
- O R^2 é dado por

$$R^2 = 1 - \frac{\sum_i (y - \hat{y}_i)^2}{\sum_i (y - \bar{y})^2}$$

- Quanto maior o número de variáveis explicativas maior o R^2 , logo um ajuste é necessário, ou seja,

$$R^2_{(adj)} = 1 - \frac{\sum_i (y - \hat{y}_i)^2 / (n - p - 1)}{\sum_i (y - \bar{y})^2 / (n - 1)}$$

- Se compararmos a função desvio de dois modelos com o mesmo tamanho de amostra, temos que aquele com o menor valor é o melhor ajustado.
- No entanto, modelos com muitos parâmetros acabam sendo beneficiados. (*overfitting*)
- O critério de informação mais famoso foi proposto por Akaike (1974)

$$AIC = 2p - 2 \log_e \hat{L}$$

onde p é o número de parâmetros

- Outro critério também popular é o BIC, proposto por Schwarz (1978)

$$BIC = p \log_e n - 2 \log_e \hat{L}$$

- Ambos critérios penalizam modelos com mais parâmetros

- Os cr terios de informa  o apresentados est o implementados no R
- As fun  es associadas se aplicam ao objeto do modelo ajustado
- No exemplo:

```
> AIC(modelo)
```

```
[1] 188.3463
```

```
> BIC(modelo)
```

```
[1] 199.0515
```

Cr terios de informa  o no R

	df	AIC	BIC	R2	R2.adj
modeloR	4.00	312.92	320.06	13.01	8.77
modeloL	4.00	239.57	246.71	83.58	82.78
modeloRL	6.00	188.35	199.05	95.32	94.84
modeloRL2	10.00	189.09	206.93	96.03	95.12

Duas explicativas categóricas: Exemplo SHHS

- Seja uma amostra de 150 participantes do SHHS (Scottish Heart Health Study), e desejamos ver como o IMC depende do histórico de tabagismo e do sexo.
- O desfecho é será o IMC (kg/m^2), e as explicativas são sexo (duas categorias) e tabagismo (3 categorias)
- Teremos quatro modelos candidatos:
 - 1 IMC (Y) versus sexo ($X_1 = \{M, F\}$)
 - 2 IMC versus tabagismo ($X_2 = \{\text{current, ex, never}\}$)
 - 3 IMC versus sexo e tabagismo
 - 4 IMC versus sexo, tabagismo, e sua interação

Modelo 1: $BMI \sim Sex$

$$Y_i | X_i \sim N(\mu_i, \sigma^2), \quad i = 1, 2, \dots, 150, \quad Y_i \perp Y_j, \forall i \neq j, \\ \mu_i = \alpha + \beta_1 X_{1,i}^{(2)}.$$

onde $X_1^{(1)}$ é a categorias de referência de sexo (Sex = M (male)).

```
> (modelo1.shhs <- lm(BMI ~ Sex, data = SHHS))
```

```
Call:
```

```
lm(formula = BMI ~ Sex, data = SHHS)
```

```
Coefficients:
```

(Intercept)	SexF
26.332	-1.112

Modelo 2: $BMI \sim Smoking$

$$Y_i | X_i \sim N(\mu_i, \sigma^2), \quad i = 1, 2, \dots, 150, \quad Y_i \perp Y_j, \forall i \neq j,$$
$$\mu_i = \alpha + \beta_2 X_{2,i}^{(2)} + \beta_3 X_{2,i}^{(3)}.$$

onde $X_2^{(1)}$ é a categoria de referência de tabagismo (Smoking = current).

```
> (modelo2.shhs <- lm(BMI ~ Smoking, data = SHHS))
```

Call:

```
lm(formula = BMI ~ Smoking, data = SHHS)
```

Coefficients:

(Intercept)	Smokingex	Smokingnever
24.527	1.691	2.279

Modelo 3: $BMI \sim Sex + Smoking$

$$Y_i | X_i \sim N(\mu_i, \sigma^2), \quad i = 1, 2, \dots, 150, \quad Y_i \perp Y_j, \forall i \neq j,$$
$$\mu_i = \alpha + \beta_1 X_{1,i}^{(2)} + \beta_2 X_{2,i}^{(2)} + \beta_3 X_{2,i}^{(3)}.$$

```
> (modelo3.shhs <- lm(BMI ~ Sex + Smoking, data = SHHS))
```

Call:

```
lm(formula = BMI ~ Sex + Smoking, data = SHHS)
```

Coefficients:

(Intercept)	SexF	Smokingex	Smokingnever
25.112	-1.340	1.655	2.483

Modelo 4: $BMI \sim Sex + Smoking + Sex : Smoking$

$$Y_i | X_i \sim N(\mu_i, \sigma^2), \quad i = 1, 2, \dots, 150, \quad Y_i \perp Y_j, \forall i \neq j,$$
$$\mu_i = \alpha + \beta_1 X_{1,i}^{(2)} + \beta_2 X_{2,i}^{(2)} + \beta_3 X_{2,i}^{(3)} + \beta_4 X_{1,i}^{(2)} X_{2,i}^{(2)} + \beta_5 X_{1,i}^{(2)} X_{2,i}^{(3)}.$$

```
> (modelo4.shhs <- lm(BMI ~ Sex * Smoking, data = SHHS))
```

Call:

```
lm(formula = BMI ~ Sex * Smoking, data = SHHS)
```

Coefficients:

(Intercept)	SexF	Smokingex	Smokingnever
25.5287	-2.2954	1.3009	1.3722
SexF:Smokingex	SexF:Smokingnever		
0.8008	2.1348		

Escolhendo modelo via ANOVA

```
> anova(modelo4.shhs)
```

Analysis of Variance Table

Response: BMI

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Sex	1	46.28	46.279	4.2317	0.0414790 *
Smoking	2	167.76	83.880	7.6700	0.0006835 ***
Sex:Smoking	2	29.78	14.892	1.3617	0.2595062
Residuals	144	1574.81	10.936		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Escolhendo o modelo

	df	AIC	BIC	R2	R2.adj
BMI ~ Sex	3.00	802.10	811.13	2.54	1.89
BMI ~ Smoke	4.00	795.19	807.23	8.16	6.91
BMI ~ Sex + Smoke	5.00	791.18	806.23	11.77	9.96
BMI ~ Sex * Smoke	7.00	792.37	813.44	13.41	10.40

Saída do modelo final

```
> summary(modelo3.shhs)
```

Call:

```
lm(formula = BMI ~ Sex + Smoking, data = SHHS)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-9.5618	-2.1509	-0.2218	1.9846	9.4236

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	25.1118	0.5071	49.522	< 2e-16 ***
SexF	-1.3400	0.5486	-2.443	0.015779 *
Smokingex	1.6545	0.6707	2.467	0.014785 *
Smokingnever	2.4829	0.6498	3.821	0.000196 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


Residual standard error: 3.315 on 146 degrees of freedom

Multiple R-squared: 0.1177, Adjusted R-squared: 0.09956

F-statistic: 6.492 on 3 and 146 DF, p-value: 0.0003737


```
> hist(rstandard(modelo3.shhs))
```

Histogram of rstandard(modelo3.shhs)



Análise de resíduos: Independência e homocedasticidade


```
> plot(rstandard(modelo3.shhs))
```



Modelo final: organizado

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	25.1118	0.5071	49.52	0.0000
SexF	-1.3400	0.5486	-2.44	0.0158
Smokingex	1.6545	0.6707	2.47	0.0148
Smokingnever	2.4829	0.6498	3.82	0.0002

Modelo final: coefplot



Exemplo: DMFT


- DMFT versus consumo de açúcar (Kg/ano) e tipo de país (Industrializado)

$$Y_i | X_i \sim N(\mu_i, \sigma^2), \quad i = 1, 2, \dots, n, \quad Y_i \perp Y_j, \forall i \neq j, \\ \mu_i = \alpha + \beta_1 X_{1,i} + \beta_2 X_{2,i}.$$

- $n = 90$ países
- X_1 é o consumo de açúcar (kg per capita / ano)
- X_2 é a classificação do país

$$X_2 = \begin{cases} 1 & \text{se país industrializado,} \\ 2 & \text{se país em desenvolvimento.} \end{cases}$$

Exemplo: DMFT versus consumo de açúcar



Quatro modelos distintos

- Modelo 1:

$$\mathbb{E}[DFMT] = \alpha + \beta_1 \text{Consumo}$$

- Modelo 2:

$$\mathbb{E}[DFMT] = \alpha + \beta_1 \text{Consumo} + \beta_2 \text{Pais}$$

- Modelo 3:

$$\mathbb{E}[DFMT] = \alpha + \beta_1 \text{Consumo} + \beta_3 \text{Consumo:Pais}$$


- Modelo 4:

$$\mathbb{E}[DFMT] = \alpha + \beta_1 \text{Consumo} + \beta_2 \text{Pais} + \beta_3 \text{Consumo:Pais}$$

Ajuste dos modelos no R

```
> # Modelo ignorando o tipo de país
> modeloC <- lm(DMFT ~ Consumo, data = dmft)
> #
> # Modelo variando intercepto
> modeloCP <- lm(DMFT ~ Consumo + Pais, data = dmft)
> #
> # Modelo variando slope
> modeloC.int <- lm(DMFT ~ Consumo + Consumo:Pais,
+                   data = dmft)
> #
> # Modelo variando intercepto e slope
> modeloCP.int <- lm(DMFT ~ Consumo + Pais + Consumo:Pais,
+                    data = dmft)
```

Modelo 1: DMFT ~ Consumo



Modelo 1: DMFT $\sim$ Consumo

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.2966	0.3062	4.23	0.0001
Consumo	0.0451	0.0089	5.06	0.0000


```
> AIC(modeloC)
```

```
[1] 319.3474
```

```
> BIC(modeloC)
```

```
[1] 326.8468
```

Modelo 2: DMFT ~ Consumo + País



Modelo 2: DMFT $\sim$ Consumo + Pais

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.6774	0.4998	3.36	0.0012
Consumo	0.0403	0.0102	3.94	0.0002
PaisEm desenvolvimento	-0.3479	0.3608	-0.96	0.3375


```
> AIC(modeloCP)
```

```
[1] 320.3903
```

```
> BIC(modeloCP)
```

```
[1] 330.3895
```

Modelo 3: $DMFT \sim \text{Consumo} + \text{Consumo}:\text{País}$



Modelo 3: DMFT $\sim$ Consumo + Consumo:Pais

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.3211	0.3129	4.22	0.0001
Consumo	0.0464	0.0094	4.92	0.0000
Consumo:PaisEm desenvolvimento	-0.0038	0.0087	-0.43	0.6680


```
> AIC(modeloC.int)
```

```
[1] 321.156
```

```
> BIC(modeloC.int)
```

```
[1] 331.1552
```

Modelo 4: $DMFT \sim \text{Consumo} * \text{País}$



Modelo 4: DMFT $\sim$ Consumo*Pais

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3.9086	1.2865	3.04	0.0032
Consumo	-0.0131	0.0301	-0.43	0.6658
PaisEm desenvolvimento	-2.7439	1.3248	-2.07	0.0413
Consumo:PaisEm desenvolvimento	0.0600	0.0320	1.88	0.0638

```
> AIC(modeloCP.int)
```

```
[1] 318.7751
```

```
> BIC(modeloCP.int)
```


```
[1] 331.2742
```

Escolhendo o modelo


	Modelo	AIC	BIC	R2	R2.adj
1	Consumo	319.35	326.85	22.53	21.65
2	Consumo + Pais	320.39	330.39	23.35	21.59
3	Consumo + Consumo:Pais	321.16	331.16	22.70	20.92
4	Consumo*Pais	318.78	331.27	26.37	23.80

Análise de resíduos do Modelo 4


Histogram of rstandard(modeloCP.int)



Análise de resíduos do Modelo 4



Análise de resíduos



Funções “não lineares”

- Em algumas situações a relação linear entre desfecho Y e exposição X pode não ser razoável.
- Podemos escrever alguns modelos não-lineares e ainda assim usar métodos de estimação de modelos lineares.
- São exemplos:
 - Modelo de exponencial:

$$Y = A \exp\{BX\}\epsilon \quad \equiv \quad \log(Y) = \log(A) + BX + \log(\epsilon)$$

- Modelo polinomial:

$$Y = \alpha + X\beta_1 + X^2\beta_2 + \cdots + X^p\beta_p$$

- Modelo logaritmo

$$Y = \alpha + \beta \log(X) + \epsilon$$

- Existem transformações no desfecho que visam “estabilizar” a variância. Box e Cox (1964) propuseram a seguinte

$$Y_i^{(\lambda)} = \begin{cases} \frac{y_i^\lambda - 1}{\lambda} & \text{se } \lambda \neq 0, \\ \log(y_i), & \text{se } \lambda = 0 \end{cases}$$

conhecida por transformação de Box-Cox.

- Padronizar variáveis explicativas contínuas torna diferentes coeficientes adimensionais e comparáveis

$$\begin{aligned} Y_i &= \alpha + \beta X + e \\ &= \alpha + \frac{sd_x}{sd_x} \beta (X + \bar{X} - \bar{X}) + e \\ &= \alpha^* + \beta^* \frac{(X - \bar{X})}{sd_x} + e \end{aligned}$$

onde $\alpha^* = \alpha + \beta \bar{X}$ e $\beta^* = \beta sd_x$

Transformando o desfecho no exemplo da dieta

```
> output2 <- lm(log(DMFT) ~ Consumo*Pais, data = dmft)
> summary(output2)
```

Call:

```
lm(formula = log(DMFT) ~ Consumo * Pais, data = dmft)
```

Residuals:

Min	1Q	Median	3Q	Max
-1.55029	-0.25373	-0.02022	0.34053	1.24113

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.38711	0.51021	2.719	0.00793 **
Consumo	-0.00588	0.01195	-0.492	0.62407
PaisEm desenvolvimento	-1.29160	0.52540	-2.458	0.01596 *
Consumo:PaisEm desenvolvimento	0.02727	0.01268	2.150	0.03432 *


Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.5457 on 86 degrees of freedom


Multiple R-squared: 0.3362, Adjusted R-squared: 0.3131

F-statistic: 14.52 on 3 and 86 DF, p-value: 9.834e-08


Transformando o desfecho no exemplo da dieta




Adicionando a incerteza




Histogram of rstandard(output2)



Normal Q-Q Plot



Análise de resíduos



Resíduos antes e depois da transformação

