

Estatística aplicada à epidemiologia II

Análise de resíduos

Leo Bastos – leonardo.bastos@fiocruz.br

PROCC – Fundação Oswaldo Cruz

<https://github.com/lbustos/eae2>

Na aula de hoje vamos rever:

- O modelo linear
- Análise de resíduos

- Seja $Y_1, Y_2, \dots, Y_n$ variáveis aleatórias independentes
- Assume-se que

$$Y_i \sim N(\mu_i, \sigma^2)$$

onde $\mu_i = \mathbf{x}_i^T \boldsymbol{\beta} = \beta_0 + \beta_1 x_{1i} + \dots + \beta_p x_{pi}$

- E o modelo é usualmente escrito como

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}, \quad \mathbf{e} \sim N_n(0, \sigma^2 \mathbf{I}_n)$$

onde

$$\mathbf{y} = \begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix}, \quad \mathbf{X} = \begin{bmatrix} \mathbf{x}_1^T \\ \vdots \\ \mathbf{x}_n^T \end{bmatrix}, \quad \mathbf{e} = \begin{bmatrix} e_1 \\ \vdots \\ e_n \end{bmatrix}$$

Inferência para os parâmetros β

- $\hat{\beta}$ pode ser encontrado por máxima verossimilhança e mínimos quadrados

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

desde que $\mathbf{X}^T \mathbf{X}$ seja singular.

- $\hat{\beta}$ é não viciado, i.e.

$$\mathbb{E}[\hat{\beta}] = \beta.$$

- a variância de $\hat{\beta}$ é dada por

$$\mathbb{V}[\hat{\beta}] = \sigma^2 (\mathbf{X}^T \mathbf{X})^{-1}$$

- E, finalmente, σ^2 é estimado usando

$$\hat{\sigma}^2 = \frac{1}{N - p} (\mathbf{y} - \mathbf{X}\hat{\beta})^T (\mathbf{y} - \mathbf{X}\hat{\beta})$$

Inferência para os parâmetros β

- ❶ O IC de 95% para o coeficiente β_i é dado por:

$$\left[\hat{\beta}_i - 1.96\sqrt{sd(\hat{\beta}_i)}; \quad \hat{\beta}_i + 1.96\sqrt{sd(\hat{\beta}_i)} \right]$$

onde o desvio padrão de $\hat{\beta}_i$ é i -ésimo valor da diagonal da matriz $\hat{\sigma}^2 = \mathbf{X}^T \mathbf{X}$.

- ❷ Se quisermos testar as hipóteses $H_0: \beta_i = b$ versus $H_1: \beta_i \neq b$, basta calcular a estatística

$$Z = \frac{\hat{\beta}_i - b}{sd(\hat{\beta}_i)}$$

e verificar onde esse valor ocorre em uma distribuição normal padrão. Calculando, por exemplo, o valor-p (ou p-value). (Teste de Wald)

- Nelder & Wedderburn (1972): $D = 2[l(\hat{\beta}_{max}) - l(\hat{\beta})]$
- Modelo normal:

$$D = \frac{1}{\sigma^2}(\mathbf{y} - \mathbf{X}\hat{\beta})^T(\mathbf{y} - \mathbf{X}\hat{\beta})$$

- Análise de variância de modelos consiste em um teste F , uma vez que a normal tem um parâmetro extra σ^2 .
- No R:
`anova(modelo, test="F")`
(O teste F é o teste default se modelo for um objeto *lm*)


Exemplo simulado

$$Y_i = 1 - 4X_{1,i} + 4X_{i,2}^{(2)} + 8X_{i,2}^{(3)} + e_i,$$


$$e_i \sim N(0, 0.5^2), \quad i = 1, 2, \dots, 350.$$

```
> n = 350
> X1 <- runif(n)
> X2 <- rbinom(n, 2, 0.5) |> factor()
> X2.dummy <- model.matrix(~X2-1)
> dados <- data.frame(x1 = X1,
+                     x2 = X2,
+                     y = 1 - 4*X1 + 4*X2.dummy[,2] +
+                     8*X2.dummy[,3] + rnorm(n, 0, .5)
+                     )
```


Exemplo simulado: Gráfico de dispersão



Exemplo simulado: Boxplot



Exemplo simulado



$$Y_i = 1 - 4X_{1,i} + 4X_{i,2}^{(2)} + 8X_{i,2}^{(3)} + e_i,$$

$$e_i \sim N(0, 0.5^2), \quad i = 1, 2, \dots, 350.$$

Call:

```
lm(formula = y ~ x1 + x2, data = dados)
```

Residuals:

Min	1Q	Median	3Q	Max
-1.4606	-0.3385	-0.0397	0.3304	8.1210

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.17199	0.09550	12.27	<2e-16 ***
x1	-4.18481	0.12833	-32.61	<2e-16 ***
x21	3.91957	0.08955	43.77	<2e-16 ***
x22	7.87831	0.10616	74.21	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.7036 on 346 degrees of freedom

Multiple R-squared: 0.9499, Adjusted R-squared: 0.9494

F-statistic: 2185 on 3 and 346 DF, p-value: < 2.2e-16

Saída R: glm()

$$Y_i = 1 - 4X_{1,i} + 4X_{i,2}^{(2)} + 8X_{i,2}^{(3)} + e_i,$$
$$e_i \sim N(0, 0.5^2), \quad i = 1, 2, \dots, 350.$$

Call:

```
glm(formula = y ~ x1 + x2, family = gaussian(), data = dados)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.17199	0.09550	12.27	<2e-16 ***
x1	-4.18481	0.12833	-32.61	<2e-16 ***
x21	3.91957	0.08955	43.77	<2e-16 ***
x22	7.87831	0.10616	74.21	<2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for gaussian family taken to be 0.4950621)

Null deviance: 3416.57 on 349 degrees of freedom
Residual deviance: 171.29 on 346 degrees of freedom
AIC: 753.16

Number of Fisher Scoring iterations: 2

Análise de variância no R

```
> anova(lm.ex)
```

Analysis of Variance Table

Response: y

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
x1	1	509.99	509.99	1030.2	< 2.2e-16 ***
x2	2	2735.28	1367.64	2762.6	< 2.2e-16 ***
Residuals	346	171.29	0.50		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Análise da Deviance no R

```
> anova(glm.ex, test="F")
```

Analysis of Deviance Table

Model: gaussian, link: identity

Response: y

Terms added sequentially (first to last)

	Df	Deviance	Resid. Df	Resid. Dev	F	Pr(>F)
NULL			349	3416.6		
x1	1	509.99	348	2906.6	1030.2	< 2.2e-16 ***
x2	2	2735.28	346	171.3	2762.6	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

- Suposições para a inferência
 - 1 Independência
 - 2 Normalidade
 - 3 Homocedasticidade (variância constante)
 - 4 Linearidade
- Como podemos verificar essas suposições?
 - Vamos estudar os resíduos, ou erros, do modelo

$$r_i = f(y_i, \hat{\mu}_i)$$

- Análises gráficas e testes formais.

Alguns possíveis resíduos

- Resíduo bruto ou ordinário

$$r_i = y_i - \hat{\mu}_i$$

- Resíduo padronizado


$$r_i = \frac{y_i - \hat{\mu}_i}{\sqrt{\mathbb{V}[\hat{\mu}_i](1 - h_i)}}$$

onde h_i é o i -ésimo elemento da matriz $\mathbf{H} = \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$


No R: `rstandard(modelo)`

- Esses resíduos podem ser usados para checar:
 - ① independência serial
 - ② Linearidade
 - ③ Normalidade
 - ④ Associação com variáveis não incluídas no modelo

Exemplo: Checando independência serial




Exemplo: Checando linearidade




- Análise visual:
 - Histograma (buscando distribuição em forma de sino)
 - quantile-quantile plot (QQnorm) (Busca por uma reta com os quantis da normal)
- Teste de hipótese (H_0 : Dados segue uma distribuição normal)
 - Teste Shapiro-wilks (*?shapiro.test*)
 - Teste Komolgorov-Smirnov (*?ks.test*)


Exemplo: Checando normalidade do desfecho




Exemplo: Checando normalidade do desfecho




Exemplo: Checando normalidade dos resíduos




Exemplo: Checando normalidade dos resíduos sem os outliers




Exemplo: Checando normalidade do resíduo



Exemplo: Checando normalidade do resíduo



Exemplo: Checando associação com uma nova variável




- Leverage (pontos de alavanca): h_{ii} (*hatvalues(modelo)*)

$$H = X^T (X^T X)^{-1} X^T$$

Valores h_{ii} maiores que 2 ou 2 vezes p/n merecem uma olhada.

- Leave-one-out measures:
 - DFFIT: Diferença nos ajustes: $\hat{y}_i - \hat{y}_{i(-i)}$
 - DFBETA: Diferença no ajuste de cada coeficiente: $\hat{\beta}_k - \hat{\beta}_{k(-i)}$
 - Distância de Cook: Diferença no ajuste em todos coeficientes

Pontos de alavanca (hatvalues)



Outliers ou pontos influentes: LOO

- DFFITS (*dffits(modelo)*) (Belsley et al. 1980)

$$DFFITS_i = \frac{\hat{y}_i - \hat{\hat{y}}_i}{s_{(i)}\sqrt{h_{ii}}} = \left(\frac{h_{ii}}{1 - h_{ii}} \right)^{1/2}$$

Investigar valores maiores que $2\sqrt{p/n}$

- DFBETAS (*dfbetas(modelo)*) (Belsley et al. 1980)


$$DFBETAS_i = \hat{\beta}_k - \hat{\beta}_{k(-i)} = \frac{(X^T X)^{-1} x_i^T (y_i - \hat{y}_i)}{1 - h_{ii}}$$

- Distância de Cook (*cooks.distance(modelo)*) (Cook 1977,1979)


$$D_i = \frac{1}{p} \left(\frac{h_{ii}}{1 - h_{ii}} \right) r_i^2$$

Cook (1979) mostrou que D_i deve ser comparado com uma $F(p, n - p)$

Outliers: DFFITS



Outliers: Distância de Cooks



Outliers: Medidas de influência


```
> summary(influence.measures(lm.ex))
```

Potentially influential observations of

```
lm(formula = y ~ x1 + x2, data = dados) :
```

	dfb.1_	dfb.x1	dfb.x21	dfb.x22	dffit	cov.r	cook.d	hat
175	0.02	-0.03	0.10	0.00	0.18	0.96_*	0.01	0.01
200	1.91_*	-1.15_*	-1.22_*	-1.03_*	1.92_*	0.14_*	0.56	0.02
300	0.45	0.01	-0.48	-0.41	0.60_*	0.70_*	0.08	0.01

Potenciais pontos influentes



Resumo: Análise gráfica de resíduos

- 1 Visão geral. (p.e. Histograma, qqnorm)
- 2 Resíduos versus sequência observada.
- 3 Resíduos versus valores ajustados.
- 4 Resíduos versus variáveis explicativas.
- 5 Resíduos versus qualquer outra forma particular que seja razoável para checar as suposições do modelo.
- 6 Busca por medidas influência (outliers ou pontos de alavanca)

- ❶ Sabemos que

$$V(\beta) = \sigma^2(X^T X)^{-1}$$

- ❷ Se alguma variável explicativa for uma combinação linear de outras então a matriz $X^T X$ não tem inversa!
- ❸ Se alguma variável explicativa for aproximadamente uma combinação linear de outras, então a variância desse coeficiente pode ter problemas.
- ❹ Perceba que

$$V(\beta_j) = \sigma^2 \left[(X^T X)^{-1} \right]_{jj} = \frac{\sigma^2}{(1 - R_j^2) \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2}.$$

onde R_j^2 é o coeficiente de determinação do modelo $X_j \sim X_{-j}$

❶ Fator de inflação de variância (VIF)

$$VIF_j = \frac{1}{1 - R_j^2}.$$

- ❷ Valores acima de 5 (ou 10) sugerem problemas (sérios) de multicolinearidade.
- ❸ O R^2 só pode ser calculado quando a variável explicativa X_j é contínua, se for categórica existe a versão generalizada GVIF
- ❹ Implementado no R no pacote `car`(Companion to applied regression)

VIF no exemplo

```
> car::vif(lm.ex)
```

	GVIF	Df	GVIF [~] (1/(2*Df))
x1	1.000068	1	1.000034
x2	1.000068	2	1.000017