


Estatística aplicada à epidemiologia II

Inferência bayesiana

Leo Bastos – leonardo.bastos@fiocruz.br

PROCC – Fundação Oswaldo Cruz

<https://github.com/lsbastos/eae2>



<https://avehtari.github.io/Bayesian-Workflow/>

Por que considerar métodos bayesianos?

- ❶ Incerteza de todas as quantidades desconhecidas podem ser expressas em termos de distribuições de probabilidades (Ganho de interpretação)
- ❷ Distribuições a priori para alguns parâmetros podem levar a distribuições a posteriori mais ressoáveis e numericamente estáveis que métodos baseados somente nos dados observados.
- ❸ Além dos dados, podemos usar múltiplas fontes de informação. Meta análise e revisão sistemática, painel de especialistas, etc.
- ❹ Modelos bayesianos podem lidar com variáveis latentes (As notas do ENEM são construídas com variáveis latentes usando a TRI)
- ❺ Construção de modelos mais complexos mantendo o procedimento de inferência (modelos mistos, espaço-temporais, etc)

- Tudo que é desconhecido pode ser representado por uma função de de “crença”
- A “crença” a respeito de algo está associada a nossa incerteza, quanto mais acreditamos na ocorrência de um certo resultado, menos incertos (ou mais certos) estamos a respeito daquele resultado.
- Podemos quantificar “crenças” ou incertezas usando probabilidades.

- Existem dois tipos de interpretação de probabilidade: Frequentista X subjetivo.
- Vamos supor o exemplo clássico em cursos de estatística: Estamos interessados na probabilidade de cara em um lançamento honesto de uma moeda honesta.
- Interpretação frequentista: Essa probabilidade é 50%, pois se realizássemos o experimento “lançar a moeda” um número muito alto de vezes, esperaríamos que metade dos experimentos resultassem cara.
- Interpretação subjetiva: Essa probabilidade é 50%, pois existem dois possíveis resultados igualmente possíveis em um lançamento de uma moeda honesta.

Exemplo: Obesidade infantil

- Qual a prevalência de obesidade infantil no município do Rio de Janeiro?
- Vamos chamar essa prevalência de θ .
- O que sabemos a respeito de θ ? Qual a nossa incerteza a respeito?
- θ por ser uma prevalência, é na verdade uma proporção estando no domínio $(0,1)$. É provável que esteja próximo de 0? E de 1? E de que outro valor?
- Podemos construir uma distribuição de probabilidades que represente o **nosso conhecimento**?
- Será que podemos atualizar nosso conhecimento usando dados de um estudo seccional realizado no município do Rio?

Teorema de Bayes-Price-Laplace

- O teorema ou regra de Bayes é um método de atualização de probabilidades.
- Foi proposto pelo rev. inglês Thomas Bayes, publicado após sua morte por Price, e desenvolvido de forma independente pelo matemático Francês Laplace.
- O teorema de Bayes-Price-Laplace:

$$P(A|B) = \frac{P(A)P(B|A)}{P(B)}$$

- Se A for o nosso parâmetro desconhecido θ , B são os nossos dados y , então

$$p(\theta|y) = \frac{p(\theta)p(y|\theta)}{p(y)}$$

Exemplo: Obesidade infantil

- Vamos supor que temos em mãos uma amostra de 100 crianças que representem* a população de crianças no Rio de Janeiro no último mês.
- Se soubéssemos o valor de θ , teríamos que o número de crianças com excesso nessa amostra seguiria uma distribuição Binomial($100, \theta$). Por quê?
- Será que conseguimos representar nosso conhecimento a priori a respeito de θ , em uma função de probabilidade $\pi(\theta)$?

Distribuição Beta


- Como θ é uma probabilidade, então $\theta \in (0, 1)$
- Uma distribuição de probabilidade que pode ser usada aqui é a distribuição Beta

$$\theta \sim \text{Beta}(a, b)$$

$$p(\theta) = \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \theta^{a-1} (1-\theta)^{b-1}$$

$$E[\theta] = \frac{a}{a+b} \quad \text{moda}[\theta] = \begin{cases} 0 & a \leq 1, b > 1, \\ \frac{a-1}{a+b-2}, & a, b > 1, \\ 1 & a > 1, b \leq 1, \\ \{0, 1\} & a, b < 1. \end{cases}$$

Distribuição Beta



Exemplo: Obesidade infantil

- Independente da escolha da priori, suponha que observamos 20 das 100 crianças com obesidade infantil.
- Vamos agora assumir que o número de crianças com sobre peso, y , segue uma distribuição Binomial, com parâmetro θ , ou seja

$$y \mid \theta \sim \text{Binom}(n = 100, \theta)$$

- Essa é a função de verossimilhança

$$p(y \mid \theta) = \binom{100}{y} \theta^y (1 - \theta)^{100-y}$$

Exemplo: Obesidade infantil

- Usando o teorema de Bayes, podemos atualizar nosso conhecimento a respeito de θ da seguinte forma:


$$\begin{aligned}\pi(\theta|y) &= \frac{\pi(\theta)\pi(y|\theta)}{\pi(y)} \\ &\propto \pi(\theta)\pi(y|\theta) \\ &\propto \pi(\theta)\theta^{20}(1-\theta)^{80}\end{aligned}$$

- Se a priori for $\theta \sim \text{Beta}(a, b)$, então

$$\pi(\theta|y) \propto \theta^{20+a-1}(1-\theta)^{80+b-1}$$

- Toda inferência a respeito de θ deve ser feita da distribuição a posteriori.


Exemplo: Obesidade infantil (Priori Uniforme)




Interpretando: Com priori uniforme

- Olhando para a distribuição a posteriori, qual a proporção de crianças com excesso de peso no Rio de Janeiro?
- O valor esperado a posteriori é 0.206. (Notem que não é 20/100, mas essa é a moda a posteriori)
- Com probabilidade 0.95, podemos dizer que a proporção de crianças obesas no Rio está entre (0.130; 0.285).
- O intervalo acima é chamado de intervalo de credibilidade de 95%.

Exemplo: Obesidade infantil (Priori com moda 0)



Exemplo: Obesidade infantil (Priori com moda 1)



Obesidade infantil: Estimativas


Priori	Posteriori	Média	Moda	Intervalo de 95%
Beta(1,1): Uniforme	Beta(21,81)	0.206	0.200	[0.130, 0.285]
Beta(1,4): Moda=0	Beta(21,84)	0.200	0.194	[0.126, 0.277]
Beta(4,1): Moda=1	Beta(24,81)	0.229	0.230	[0.151, 0.309]

- A distribuição a posteriori para as quantidades desconhecidas tem toda a informação que precisamos.
- É comum reduzir, ou simplificar, a distribuição a posteriori em algumas medidas.
 - Estimativas pontuais: valor esperado, mediana, moda.
 - Medidas de incerteza: desvio padrão, intervalos interquartílicos, intervalos de credibilidade.
- Notem que o exemplo foi feito com um parâmetro desconhecido, nada impede que tenhamos vários parâmetros desconhecidos.

Exemplo: Prevalência de chikungunya

- Qual a prevalência de chikungunya no município do Rio de Janeiro?
- Como podemos estimar essa prevalência? (Vamos defini-la como θ)
- Se elicitarmos uma priori para θ , onde vai ser a região mais provável? O que sabemos?
- Uma vez construída nossa priori, podemos atualizá-la com um estudo realizado aqui no município no ano de 2018.

Alguma dessas pode representar nosso conhecimento?



O modelo para prevalência de CHIKV

- Em um estudo na cidade, pessoas serão aleatoriamente selecionadas e convidadas a participar de um estudo sorológico de chikungunya.
- Um amostra de sangue será coletada e será testado se a pessoa já teve infecção prévia do CHIKV.
- Seja n número de pessoas selecionadas e y o total de pessoas soroprevalentes, ou seja

$$Y \mid \theta \sim \text{Bin}(n, \theta)$$

- Vimos que uma priori $\text{Beta}(a, b)$ para θ vai nos dar uma posteriori

$$\theta \mid Y = y \sim \text{Beta}(a + y, b + n - y)$$

Prevalência de DZC no Rio de Janeiro, 2018



The screenshot shows the PLOS One website interface. At the top is the PLOS One logo and navigation links: About, Browse, Publish, and a search bar with a magnifying glass icon and the text "advanced search". Below the header, there are icons for "OPEN ACCESS" and "PEER-REVIEWED", followed by the text "RESEARCH ARTICLE". The main title of the article is "Zika, dengue and chikungunya population prevalence in Rio de Janeiro city, Brazil, and the importance of seroprevalence studies to estimate the real number of infected individuals". Below the title, the authors are listed: André Reynaldo Santos Périssé, Reinaldo Souza-Santos, Rosemere Duarte, Fernanda Santos, Célia Regina de Andrade, Nádia Cristina Pinheiro Rodrigues, Joyce Mendes de Andrade Schramm, Edmilson Domingues da Silva, Ludmilla da Silva Viana Jacobson, Maria Cristina Ferreira Lemos, and Andrea Sobral. The publication date is December 17, 2020, and the DOI is https://doi.org/10.1371/journal.pone.0243239. On the right side, there are statistics: 116 Save, 49 Citation, 4,757 View, and 2 Share. At the bottom, there are buttons for "Download PDF", "Print", and "Share". A table with five columns (Article, Authors, Metrics, Comments, Media Coverage) is partially visible at the bottom left.

PLOS One

About Browse Publish Search advanced search

OPEN ACCESS PEER-REVIEWED
RESEARCH ARTICLE

Zika, dengue and chikungunya population prevalence in Rio de Janeiro city, Brazil, and the importance of seroprevalence studies to estimate the real number of infected individuals

André Reynaldo Santos Périssé, Reinaldo Souza-Santos, Rosemere Duarte, Fernanda Santos, Célia Regina de Andrade, Nádia Cristina Pinheiro Rodrigues, Joyce Mendes de Andrade Schramm, Edmilson Domingues da Silva, Ludmilla da Silva Viana Jacobson, Maria Cristina Ferreira Lemos, Andrea Sobral

Published: December 17, 2020 • <https://doi.org/10.1371/journal.pone.0243239>

116 Save 49 Citation
4,757 View 2 Share


Download PDF Print Share

Article	Authors	Metrics	Comments	Media Coverage
---------	---------	---------	----------	----------------


<https://pmc.ncbi.nlm.nih.gov/articles/PMC7746276/>

- Périssé et al. (2020, PLOS One)
- $N = 2120$ e $Y = 371$ (17.5%)

Posteriori para a prevalência de CHIKV em 2018



Posteriori para a prevalência de CHIKV em 2018



Prevalência de CHIKV em 2018

- A partir da posteriori temos que a prevalência de CHIKV em 2018 é estimada em 17.5% (15.9%; 19.2%)
- O artigo apresentou 18.0% com intervalo (14.8%; 21.2%) (Uso de pesos amostrais por conta da amostra complexa utilizada)
- Temos uma prevalência baixa, com potencial para um novo surto.


Casos de chikungunya notificados no Rio de Janeiro

Chikungunya Situation - Rio de Janeiro at Aug. 29, 2026

- Population: 6.6 million of inhabitants.
- Estimated Incidence epidemiological week 34: 0.9 per 100 thousand inhabitants.
- Arbovirolosis Situation report of : [Rio de Janeiro](#)
- For more details go to the States page: [RJ](#)

Select the disease to be shown ☐ Dengue ☒ Chikungunya ☐ Zika

Chance de alerta laranja ou vermelho de Chikungunya para o município de Rio de Janeiro na próxima semana: 47.7%



<https://info.dengue.mat.br/alerta/3304557/chikungunya>

Inferência bayesiana para um modelo linear

- Sejam $Y_1, Y_2, \dots, Y_n$ variáveis aleatórias independentes
- Cada $Y_i \mid \mu_i, \sigma^2 \sim N(\mu_i, \sigma^2)$.
- As variáveis explicativas $x_{i1}, \dots, x_{ip}$ influenciam a variável resposta através de um preditor linear


$$\mu_i = \mathbf{x}_i^T \boldsymbol{\beta} = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}$$

- Os parâmetros desconhecidos são $\boldsymbol{\beta} = (\beta_0, \beta_1, \dots, \beta_p, \sigma^2)$.

Priori para (β, σ^2)

- Quais são os possíveis valores de $(\beta, \sigma^2) = (\beta_0, \beta_1, \dots, \beta_p, \sigma^2)$?
- $\beta = (\beta_0, \beta_1, \dots, \beta_p) \in \mathbb{R}^{p+1}$ e $\sigma^2 > 0$
- Candidatos a distribuição a priori para β
 - Normal $p + 1$ variada com vetor de média b e matriz de variância V
 - $p + 1$ normais univariadas independentes, $\beta_k \sim N(b_k, v_k)$
 - $p + 1$ t de Student independentes, $\beta_k \sim t_\nu(b_k, v_k)$
- b_k e v_k representam a nossa incerteza a respeito de β_k
- Quanto maior v_k , maior a nossa incerteza, e menos informativa é a nossa priori.

Prioris para β



- Candidatos a distribuição a priori para σ^2
 - $\sigma^2 \sim \text{Gamma}(a, b)$
 - $\sigma^2 \sim \text{InvGamma}(a, b)$
 - $\sigma^2 \sim \text{logNormal}(m, v)$
- Nesse momento, não vamos nos preocupar com σ^2

Posteriori para (β, σ^2)

- Usando o teorema de Bayes podemos obter a posteriori para (β, σ^2)

$$\pi(\beta, \sigma^2 \mid Y, X) \propto L(\beta, \sigma^2) \pi(\beta, \sigma^2)$$

- A função de verossimilhança, $L(\beta, \sigma^2)$, é dada por

$$L(\beta, \sigma^2) \propto (\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2}(Y - X\beta)^T(Y - X\beta)\right\}$$

- Dependendo da priori, a distribuição a posteriori pode não ser analiticamente tratável.

- Métodos numéricos podem ser necessários, tais métodos podem ser programados pelo usuários ou implementados em softwares para classes de modelos:
 - Inferência via MCMC (JAGS, Stan, NIMBLE)
 - Inferência baseada em aproximações (pacote arm, INLA)
- Todos tem interface com o R.
- Para modelos lineares pode-se usar a função 'bayesglm' do pacote 'arm'.


```
> library(arm)
> n = 30
> x = runif(n)
> y = rnorm(n, mean = 1 + 2 * x, sd = 0.5)
> bayesglm(y ~ x, family=gaussian, prior.df=Inf,
+          prior.mean = 0, prior.mean.for.intercept = 0,
+          prior.scale=10, prior.scale.for.intercept = 10)

Call: bayesglm(formula = y ~ x, family = gaussian, prior.mean = 0,
               prior.scale = 10, prior.df = Inf, prior.mean.for.intercept = 0,
               prior.scale.for.intercept = 10)
```

Coefficients:

(Intercept)	x
1.094	1.951

Degrees of Freedom: 29 Total (i.e. Null); 28 Residual

Null Deviance: 17.06

Residual Deviance: 6.224 AIC: 43.95

bayesglm: $\beta_0 = 1$ e $\beta_1 = 2$


- Média a posteriori e intervalo de credibilidade

	Mean	2.5 %	97.5 %
(Intercept)	1.09	0.78	1.41
x	1.95	1.40	2.50

- Saída do lm()


	Mean	2.5 %	97.5 %
(Intercept)	1.09	0.77	1.42
x	1.95	1.38	2.52

Previsão para o valor esperado de Y



Expectativa de vida (OMS)

- O arquivo "data_oms.csv" tem a expectativa de vida (ao nascer e aos 60 anos) por sexo de 2000 a 2021 para 185 países. (Dados tratados)
- Vamos ajustar um modelo para expectativa de vida ao nascer segundo sexo e região da OMS em dois anos distintos (2015 e 2021).




[https://www.who.int/data/gho/data/indicators/
indicator-details/GHO/life-expectancy](https://www.who.int/data/gho/data/indicators/indicator-details/GHO/life-expectancy)

Lendo os dados

```
> library(tidyverse, quietly = T, warn.conflicts = F)
> life_exp_oms <- read.csv("../dados/data_oms.csv")
> life_exp_2015 <- life_exp_oms |>
+   filter(
+     Indicator == "Life expectancy at birth (years)",
+     # Indicator == "Life expectancy at age 60 (years)",
+     Dim1 != "Both sexes",
+     Period == 2015
+   ) |>
+   # Selecionando e renomeando apenas as variaveis que eu vou usar
+   transmute(
+     Ano = Period, Sexo = factor(Dim1), RegiaoOMS = factor(ParentLocation),
+     Pais = Location, ExpVida = FactValueNumeric)
```

Expectativa de vida segundo sexo



Expectativa de vida ao nascer

```
> output <- bayesglm(formula = ExpVida ~ Sexo + RegiaoOMS,  
+                      family = gaussian, data = life_exp_2015)
```

```
> output
```

```
Call: bayesglm(formula = ExpVida ~ Sexo + RegiaoOMS, family = gaussian,  
data = life_exp_2015)
```

Coefficients:


(Intercept)	SexoMale
77.544	-4.857
RegiaoOMSAfrica	RegiaoOMSEastern Mediterranean
-12.569	-3.160
RegiaoOMSEurope	RegiaoOMSSouth-East Asia
2.347	-2.795
RegiaoOMSWestern Pacific	
-2.625	

Degrees of Freedom: 369 Total (i.e. Null); 363 Residual


Null Deviance: 24650

Residual Deviance: 10430 AIC: 2301

Coefplot



Expectativa de vida segundo sexo e região da OMS



Expectativa de vida ao nascer

```
> output2 <- bayesglm(formula = ExpVida ~ Sexo + RegiaoOMS,  
+                       family = gaussian, data = life_exp_2021)
```

```
> output2
```

```
Call: bayesglm(formula = ExpVida ~ Sexo + RegiaoOMS, family = gaussian,  
data = life_exp_2021)
```


Coefficients:

(Intercept)	SexoMale
75.3600	-4.8468
RegiaoOMSAfrica	RegiaoOMSEastern Mediterranean
-9.4018	-1.7061
RegiaoOMSEurope	RegiaoOMSSouth-East Asia
3.9945	-0.7190
RegiaoOMSWestern Pacific	
-0.5017	

Degrees of Freedom: 369 Total (i.e. Null); 363 Residual

Null Deviance: 21290

Residual Deviance: 10010 AIC: 2286



Comparando 2015 com 2021

		Est.2015	Est.2021
1	(Intercept)	77.54	75.36
2	SexoMale	-4.86	-4.85
3	RegiaoOMSAfrica	-12.57	-9.40
4	RegiaoOMSEastern Mediterranean	-3.16	-1.71
5	RegiaoOMSEurope	2.35	3.99
6	RegiaoOMSSouth-East Asia	-2.80	-0.72
7	RegiaoOMSWestern Pacific	-2.63	-0.50

- Replique as análises
- Avalie o efeito do sexo e região da OMS na expectativa de vida aos 60 anos.
- Escolha um país e estime o número de anos perdidos na expectativa de vida ao nascer (e aos 60 anos) durante a pandemia de COVID-19.

Expectativa de vida ao longo do tempo

```
> life_exp_BR <- life_exp_oms |>
+   filter(Location == "Brazil",
+           Indicator == "Life expectancy at birth (years)",
+           Dim1 == "Both sexes")
> modelo <- bayesglm( FactValueNumeric ~ Period, family = gaussian,
+                    data = life_exp_BR |> filter(Period < 2020))
> g1 <- life_exp_BR |>
+   ggplot( aes(x=Period, y=FactValueNumeric)) +
+     geom_point() +
+     theme_bw()
```

Expectativa de vida ao longo do tempo

