

Estatística aplicada à epidemiologia II

Análise de resíduos

Leo Bastos – leonardo.bastos@fiocruz.br

PROCC – Fundação Oswaldo Cruz

<https://github.com/lbustos/eae2>

- É o desfecho mais comum em epidemiologia
- Óbito $\{S, N\}$; Sobrepeso $\{IMC > 25, IMC \leq 25\}$; Infectado $\{S, N\}$; etc.
- A variável aleatória associada a um desfecho binário assume apenas dois valores numéricos, usualmente $\{0, 1\}$.
- Exemplo:

$$Y = \begin{cases} 1, & \text{tem o desfecho de interesse,} \\ 0, & \text{não tem o desfecho de interesse.} \end{cases}$$

Os dados binários podem ser apresentados em sua forma bruta:

	Y	X1	X2
1	0	1	Tratamento 1
2	1	1	Tratamento 2
3	1	1	Tratamento 1
4	1	1	Tratamento 1
5	1	0	Tratamento 1
6	1	1	Tratamento 1
7	0	0	Controle
8	0	1	Tratamento 2

Ou na forma agregada:

	Y	n	X1	X2
1	3	10	0	Controle
2	6	30	0	Tratamento 1
3	12	45	0	Tratamento 2
4	3	20	1	Controle
5	20	50	1	Tratamento 1
6	1	15	1	Tratamento 2

Modelo para dados binários

- Seja $Y_1, Y_2, \dots, Y_n$ variáveis aleatórias independentes
- O desfecho é binário, i.e. $Y_i = \{0, 1\}$
- A distribuição usada para dados binários é a distribuição Bernoulli

$$Y_i \sim \text{Bern}(\theta_i)$$

onde $\theta_i = P(Y_i = 1) \in (0, 1)$.

- Nosso interesse se encontra em tentar explicar a probabilidade do desfecho de interesse θ_i .
- Isso é feito de forma similar ao modelo linear

Modelo para dados binários

- No modelo

$$Y_i \sim \text{Bern}(\theta_i)$$

onde $\theta_i = P(Y_i = 1) \in (0, 1)$.

- Tentamos explicar uma função da probabilidade θ_i a partir de uma variável exposição X da seguinte forma:

$$g(\theta_i) = \alpha + \beta x_i$$

onde $g(\cdot)$ é uma função que leva dos valores entre 0 e 1 para os reais, em matemáticos $g(\cdot) : (0, 1) \rightarrow \mathbb{R}$

- A função mais popular que cumpre esse papel é a função logit.


- A função logit é definida por

$$\text{logit}(\theta) = \log \left(\frac{\theta}{1 - \theta} \right)$$

- O componente $\frac{\theta}{1-\theta}$ é conhecido por chance ou odds
- Veja a tabela abaixo:

	Prob	Odds	log(Odds)
1	0.10	0.11	-2.20
2	0.25	0.33	-1.10
3	0.50	1.00	0.00
4	0.75	3.00	1.10
5	0.90	9.00	2.20
6	0.99	99.00	4.60

Função logit



logit(θ)

- $+1+2x$
- $-1+2x$
- $+1-2x$

- Seja

$$Y_i \sim \text{Bern}(\theta_i)$$

onde $\theta_i = P(Y_i = 1) \in (0, 1)$.

- Suponha que temos uma exposição X
- Usando a função de ligação logit, temos que

$$\text{logit}(\theta_i) = \alpha + \beta x_i$$

Função logit

- Na epidemiologia, uma medida de associação bastante popular é a razão de chances.
- Suponha uma exposição binária, $X = \{0, 1\}$, e $\theta_1 = P(Y = 1 \mid X = 1)$, e $\theta_0 = P(Y = 1 \mid X = 0)$
- A razão de chances, ou odds ratio, de X é dada por

$$OR_X = \frac{\text{chance}(X = 1)}{\text{chance}(X = 0)} = \frac{\frac{\theta_1}{1-\theta_1}}{\frac{\theta_0}{1-\theta_0}}$$

- Lembrando que:

$$\text{logit}(\theta_x) = \log\left(\frac{\theta_x}{1-\theta_x}\right) = \log(\text{chance}(X = x)) = \alpha + \beta x$$

$$\Rightarrow \text{chance}(X = x) = \frac{\theta_x}{1-\theta_x} = \exp\{\alpha + \beta x\}$$

- Logo a razão de chances de interesse é

$$OR_X = \frac{\frac{\theta_1}{1-\theta_1}}{\frac{\theta_0}{1-\theta_0}} = \frac{\exp\{\alpha + \beta \times 1\}}{\exp\{\alpha + \beta \times 0\}} = \exp\{\beta\}$$

- Ou seja,

$$OR_X = \exp\{\beta_1\}$$

Exemplo: Fumo na gestação versus baixo peso

- Em um estudo observacional sobre tabagismo na gestação realizado em um certo hospital, uma amostra de 189 puérperas foi aleatoriamente selecionada.
- Foi verificado se as mulheres fumaram ou não durante a gestação.
- o peso do recém nascido foi registrado, e categorizado como baixo peso sim ou não.
- Os dados observados foram

Fumou durante a gestação?	Baixo peso ao nascer?	
	Sim	Não
Sim	30	44
Não	29	86

- A tabela de contingência Baixo peso ao nascer x mãe fumou durante gravidez

Fumou durante a gestação?	Baixo peso ao nascer?	
	Sim	Não
Sim	30	44
Não	29	86

- Calculando a OR:

$$OR = ?$$

- Essa OR é estatisticamente significativa?

Construindo o modelo

- Vamos construir o modelo desse exemplo
- Quem é o desfecho, Y ?
 - Peso do recém nascido ($Y = 1$ se baixo peso)
- Quem é a exposição, X ?
 - Fumo durante a gestação ($X = 1$ sim)
- Como é o modelo?
 - O modelo é dado por

$$Y \mid X = x \sim \text{Bernoulli}(\theta_x)$$

$$\text{onde } \text{logit}(\theta_x) = \alpha + \beta x$$

- No R, usamos a função *glm*

```
> saida <- glm(low ~ smoke,  
+              family=binomial(link = 'logit'),  
+              data=birth)
```

- Precisamos especificar a família, nesse caso é a Binomial (Lembrem-se que a $Bernoulli(\theta) = Binomial(1, \theta)$)
- A função de ligação default é a logit.

- A saída da função *glm* é bastante similar a saída da função *lm*

```
Call: glm(formula = low ~ smoke, family = binomial(link = "logit"),
  data = birth)
```

```
Coefficients:
```

```
(Intercept)      smokesim
   -1.0871         0.7041
```

```
Degrees of Freedom: 188 Total (i.e. Null);  187 Residual
```

```
Null Deviance:                234.7
```

```
Residual Deviance: 229.8      AIC: 233.8
```

- Calculando a OR

```
> exp(0.7041)
```

```
[1] 2.022026
```


- Essa OR é significativa? (i.e. $H_0: OR = 1$ versus $H_1: OR \neq 1$)
- Como a $OR = \exp(\beta)$, então o teste acima, é equivalente a testar $H_0: \beta = 0$ versus $H_1: \beta \neq 0$.
- Ou, alternativamente, podemos calcular um IC de 95% de confiança para a OR (ou para β)
- Um possível intervalo de 95% para a OR é dado pela exponencial do intervalo de 95% para β .
- Note que dessa forma o intervalo para a OR não é mais simétrico em torno da estimativa pontual, mas continua sendo um IC de 95% válido.

Saidas no R

Call:

```
glm(formula = low ~ smoke, family = binomial(link = "logit"),  
     data = birth)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-1.0871	0.2147	-5.062	4.14e-07	***
smokesim	0.7041	0.3196	2.203	0.0276	*

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 234.67 on 188 degrees of freedom
Residual deviance: 229.80 on 187 degrees of freedom
AIC: 233.8

Number of Fisher Scoring iterations: 4

- O IC para os coeficientes podemos ser calculados da seguinte forma

```
> cbind(saida$coef, confint(saida) )
```

		2.5 %	97.5 %
(Intercept)	-1.0870515	-1.5243118	-0.679205
smokesim	0.7040592	0.0786932	1.335154

- E o IC para o coeficiente é dado por

```
> exp(cbind(OR=saida$coef, confint(saida) ))[-1,]
```

	OR	2.5 %	97.5 %
	2.021944	1.081872	3.800582

- Se for de interesse (e o delineamento do estudo permitir) podemos estimar a probabilidade do desfecho ocorrer sob condições específicas das variáveis explicativas.
- Ou seja,

$$P(Y_i = 1|X = x) = \text{logit}^{-1}(\alpha + \beta x)$$

- Para o modelo logístico:

$$P(Y_i = 1|X = x) = \frac{e^{\alpha + \beta x}}{1 + e^{\alpha + \beta x}}$$

- Logo, previsões para essas probabilidades são dados por

$$\hat{P}(Y_i = 1|X = x) = \frac{e^{\hat{\alpha} + \hat{\beta}x}}{1 + e^{\hat{\alpha} + \hat{\beta}x}}$$

No exemplo

- No exemplo, podemos estimar a probabilidade de baixo para mulheres que fumam e para mulheres que não fumam durante a gravidez.
- Basta usar a função *predict*

```
> birth.pred <- data.frame(smoke = c("sim", "nao"))  
> prev <- predict(saida, type = 'response',  
+                 newdata = birth.pred)  
> prev  
  
          1          2  
0.4054054 0.2521739
```

Intervalo de confiança para a previsão

- Para evitar 'esquisitices' o intervalo de confiança para as previsões exigem um pouco mais de algebrismo.

```
> prev2 <- predict(saida, type = 'link',  
+                 newdata = birth.pred,  
+                 se.fit = T)
```

- Criando os intervalos

```
> birth.pred <- birth.pred %>%  
+   bind_cols(  
+     Prob = prev,  
+     Link = prev2$fit,  
+     Link.sd = prev2$se.fit  
+   )
```

- A tabela estimada:

	smoke	Prob	Link	Link.sd
1	sim	0.405	-0.383	0.237
2	nao	0.252	-1.087	0.215

- IC para $\eta = \alpha + \beta x$

	smoke	Link	Link.sd	LI	LS
1	sim	-0.383	0.237	-0.847	0.081
2	nao	-1.087	0.215	-1.508	-0.666

- IC para $\theta_x = \text{logit}^{-1}(\alpha + \beta x)$

	smoke	Prob	LI	LS
1	sim	0.405	0.300	0.520
2	nao	0.252	0.181	0.339

- Vamos explorar o exemplo do famoso naufrágio de Titanic em 1912.
- O dado original consiste em um array com 4 dimensões dos 2201 passageiros contendo as seguintes informações:
 - Survived: {Yes, No}
 - Sex: {Male, Female}
 - Age: {Child, Adult}
 - Class: {1st, 2nd, 3rd, Crew}
- “Mulheres e crianças primeiro!”, será que isso aconteceu no naufrágio do Titanic?
- Como podemos verificar isso?

- Podemos explicar a probabilidade de sobreviver segundo sexo e idade
- Podemos comparar as probabilidades (ou avaliar as ORs) associadas a sobrevivência entre os sexos, e entre os dois grupos de idade.
- Então, basta calcularmos as ORs

$$OR_{Sex:Female} = \frac{Odds(Female)}{Odds(Male)}$$

e

$$OR_{Age:Child} = \frac{Odds(Child)}{Odds(Adult)}$$

Lendo os dados no R

- Chamando o banco

```
> data("Titanic")  
> Titanic2 <- Titanic |> as_tibble() |>  
+   pivot_wider(names_from = Survived, values_from = n)  
> head(Titanic2, n = 5)
```

```
# A tibble: 5 × 5
```


	Class	Sex	Age	No	Yes
	<chr>	<chr>	<chr>	<dbl>	<dbl>
1	1st	Male	Child	0	5
2	2nd	Male	Child	0	11
3	3rd	Male	Child	35	13
4	Crew	Male	Child	0	0
5	1st	Female	Child	0	1

Definindo categorias de base

- Transformando em fatores e definindo categorias de base

```
> Titanic2 <- Titanic2 |>  
+   mutate(  
+     Sex = factor(Sex) |> relevel(ref = "Male"),  
+     Age = factor(Age) |> relevel(ref = "Adult"),  
+     Class = factor(Class) |> relevel(ref = "Crew")  
+   )
```

Visualizando: Sobrevivência por sexo




- Tabela para Sexo

	Sex	Surv:Yes	Surv:No
1	Male	367	1364
2	Female	344	126

- $OR_{Sex:Female} = \frac{1364 \cdot 344}{367 \cdot 126} = 10.15$
- As chances de uma mulher sobreviver ao naufrágio são 10.15 vezes as chances de um homem sobreviver.

Visualizando: Sobrevivência por idade



- Tabela para Sexo

	Age	Surv:Yes	Surv:No
1	Adult	654	1438
2	Child	57	52

- $OR_{Age:Child} = \frac{57 \cdot 1438}{52 \cdot 654} = 2.41$
- As chances de uma criança sobreviver ao naufrágio são 2.41 vezes as chances de um adulto sobreviver.

- O modelo logístico tem a forma

$$Y_i \sim \text{Ber}(\theta_i)$$

onde $Y_i = 1$ se o indivíduo sobreviveu, $g(\theta_i) = \alpha + \beta X_i$

- Se o dado estiver agregado, cada linha representa um conjunto de categorias, podemos escrever o modelo da seguinte forma
- O modelo logístico tem a forma

$$Z_k \sim \text{Bin}(n_k, \theta_k)$$

onde Z_k é o número de sobreviventes na linha k , n_k o número de passageiros na linha k , e $g(\theta_k) = \alpha + \beta X_k$

Olhando o dado agregado

- O dado em sua forma agregada

```
> head(Titanic2)
```

```
# A tibble: 6 × 5
```

	Class	Sex	Age	No	Yes
	<fct>	<fct>	<fct>	<dbl>	<dbl>
1	1st	Male	Child	0	5
2	2nd	Male	Child	0	11
3	3rd	Male	Child	35	13
4	Crew	Male	Child	0	0
5	1st	Female	Child	0	1
6	2nd	Female	Child	0	13

Modelos para dados agregados

```
> m0Sex <- glm(cbind(Yes, No) ~ Sex,  
+             data = Titanic2,  
+             family=binomial())  
> m0Age <- glm(cbind(Yes, No) ~ Age,  
+             data = Titanic2,  
+             family=binomial())
```

- $(Surv : Y, Surv : N) \sim Sex$

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.3128	0.0588	-22.33	0.0000
SexFemale	2.3172	0.1196	19.38	0.0000

- $OR_{SexFemale} = 10.15$

- $(Surv : Y, Surv : N) \sim Age$

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.7879	0.0472	-16.71	0.0000
AgeChild	0.8797	0.1975	4.45	0.0000


- $OR_{Age:Child} = 2.41$

- Podemos encontrar as ORs ajustadas, i.e. a OR do sexo ajustada por idade, e a OR da idade ajustada pelo sexo.
- $(Surv : Y, Surv : N) \sim Age + Sex$

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.3365	0.0599	-22.32	0.0000
SexFemale	2.2940	0.1199	19.13	0.0000
AgeChild	0.5564	0.2276	2.44	0.0145

- $OR_{SexFemale} = 9.91$ e $OR_{AgeChild} = 1.74$

Visualizando: Sobrevivência por idade e sexo



- $(Surv : Y, Surv : N) \sim Age$ (para os homens)

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.3691	0.0609	-22.47	0.0000
AgeChild	1.1811	0.2584	4.57	0.0000

- $(Surv : Y, Surv : N) \sim Age$ (para as mulheres)

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	1.0644	0.1111	9.58	0.0000
AgeChild	-0.5654	0.3269	-1.73	0.0837

Criando uma categoria única Sexo e idade

- Agora vamos criar uma categoria para sexo e idade, vamos chamá-la de SexAge.
- $(Surv : Y, Surv : N) \sim AgeSex$

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.3691	0.0609	-22.47	0.0000
AgeSexAdult:Female	2.4335	0.1267	19.21	0.0000
AgeSexChild:Female	1.8681	0.3134	5.96	0.0000
AgeSexChild:Male	1.1811	0.2584	4.57	0.0000

- Lembrando que podemos recuperar as probabilidades aplicando a função logit inversa,

$$\hat{\theta} = \text{logit}^{-1}\left(\alpha + \sum_i \text{AgeSex}_i \hat{\beta}_i\right)$$

- Resultando na tabela:

	Levels	OR	SurvProb	LI	LS
1	Adult:Male	1.000	0.203	0.184	0.223
2	Adult:Female	11.399	0.744	0.700	0.783
3	Child:Female	6.476	0.622	0.474	0.751
4	Child:Male	3.258	0.453	0.336	0.575


- Comparando modelos via AIC

	Modelos	AIC
1	1 + Age	703.02
2	1 + Sex	288.11
3	1 + Age + Sex	284.22
4	1 + AgeSex	269.90

Conclusão?

- E aí, Mulheres e crianças primeiro?
- Mulheres adultas primeiro, depois crianças!

Visualizando: Sobrevivência por classe



Modelo adicionando a Classe

- $(Surv : Y, Surv : N) \sim AgeSex + Class$

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.2389	0.0807	-15.35	0.0000
AgeSexAdult:Female	2.6172	0.1510	17.33	0.0000
AgeSexChild:Female	2.5072	0.3332	7.52	0.0000
AgeSexChild:Male	1.7921	0.2829	6.33	0.0000
Class1st	0.8033	0.1598	5.03	0.0000
Class2nd	-0.2305	0.1771	-1.30	0.1932
Class3rd	-1.0072	0.1530	-6.58	0.0000

- ORs por classe (Baseline: Crew)

	OR	LI	LS
Class1st	2.23	1.63	3.05
Class2nd	0.79	0.56	1.12
Class3rd	0.37	0.27	0.49

- ORs por Idade e sexo (Baseline: Adult:Male)

	OR.crude	OR.adj
AgeSexAdult:Female	11.40	13.70
AgeSexChild:Female	6.48	12.27
AgeSexChild:Male	3.26	6.00

- $(Surv : Y, Surv : N) \sim AgeSex$ (AIC = 269.9)
- $(Surv : Y, Surv : N) \sim AgeSex + Class$ (AIC = 155.2)

Probabilidades de sobrevivência

