

Estatística aplicada à epidemiologia II

Modelo logístico

Leo Bastos – leonardo.bastos@fiocruz.br

PROCC – Fundação Oswaldo Cruz

<https://github.com/lsbastos/eae2>

Regressão logística múltipla

- O modelo logístico ~~multivariado~~ múltiplo
- Seja Y um desfecho binário, e $X_1, X_2, \dots, X_p$, p variáveis explicativas.
- O modelo de regressão logística é dado por

$$Y_i \sim \text{Bernoulli}(\theta_i)$$

onde

$$\text{logit}(\theta_i) = \alpha + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_p X_{pi}$$

- Exponencial dos coeficientes pode ser interpretado como razão de chances da variável associada ao coeficiente fixada todas as outras em um mesmo valores (independente qual for esse valor).

A função de ligação *logit*

- Função *logit*

$$\log\left(\frac{\theta_i}{1 - \theta_i}\right) = \mathbf{x}_i^T \boldsymbol{\beta} = \eta_i \Rightarrow \mu_i = \frac{e^{\eta_i}}{1 + e^{\eta_i}}$$

- Suponha que dois cenários serão comparados, onde a única diferença entre eles é a variável x_k , que assume valor a em um cenário e b no outro.

$$\log\left(\frac{\theta_{(x_k=x)}}{1 - \theta_{(x_k=x)}}\right) = \mathbf{x}_{-k}^T \boldsymbol{\beta}_k + x \beta_k \Rightarrow \frac{\theta_{(x_k=x)}}{1 - \theta_{(x_k=x)}} = \exp\{\mathbf{x}_{-k}^T \boldsymbol{\beta}_k + x \beta_k\}$$

- Logo a razão de chances de interesse é

$$OR = \frac{\frac{\theta_{(x_k=a)}}{1 - \theta_{(x_k=a)}}}{\frac{\theta_{(x_k=b)}}{1 - \theta_{(x_k=b)}}} = \frac{\exp\{\mathbf{x}_{-k}^T \boldsymbol{\beta}_k + a \beta_k\}}{\exp\{\mathbf{x}_{-k}^T \boldsymbol{\beta}_k + b \beta_k\}} = \exp\{\beta_k(a - b)\}$$

- Se $a = 1$ e $b = 0$ então

$$OR = \exp\{\beta_1\}$$

Exemplo: Sífilis em usuários de drogas

- Seja um estudo transversal que recrutou aleatoriamente 605 usuários de drogas (heavy drug users)
- Heavy drug user: É aquele usuário que: usou droga injetável nos últimos 6 meses e/ou usou droga da pasta base da cocaína pelo menos 25 vezes nos últimos 6 meses.
- Tem-se o interesse em quantificar, entre outras coisas, a associação entre a infecção de sífilis com sexo e idade dos participantes do estudo.

Exemplo: Sífilis em usuários de drogas

```
> # dados <- read.csv("Aula6_binary/DUsifilis.csv")  
> dados <- read.csv("../dados/DUsifilis.csv")  
> head(dados)
```

	sifilis	sexo	idade	faixaetaria
1	0	masculino	46	35 a 49 anos
2	0	masculino	29	25 a 34 anos
3	0	masculino	44	35 a 49 anos
4	0	masculino	20	18 a 24 anos
5	0	masculino	26	25 a 34 anos
6	0	masculino	39	35 a 49 anos

- $Sifilis \sim Sexo$

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.7975	0.1703	-4.68	0.0000
sexomasculino	-0.5443	0.2067	-2.63	0.0084

- $OR_{Sexo:Masculino} = 0.58$. (Qual a interpretação?)

Mudando a referência

- Eu gostaria de interpretar como aumento na OR, olhar a OR com a mulher no numerador.
- Solução rápida, inverter o sinal do β . Pois
 $OR_{Sexo:Masculino} = 1/OR_{Sexo:Feminino}$ (É mesmo?)
- E portanto, $OR_{Sexo:Feminino} = 1/OR_{Sexo:Masculino} = 1/e^{\beta} = e^{-\beta}$
- No exemplo: $OR_{Sexo:Feminino} = 1/OR_{Sexo:Masculino} = 1.72$
- Um outro caminho, mudar a categoria de base no R usando a função `relevel()`.

Mudando a categoria de base

- $Sifilis \sim Sexo + Idade$

```
> dados$sexo = relevel(factor(dados$sexo),  
+                             ref = "masculino")  
> m0Sex <- glm(sifilis ~ sexo,  
+              dados, family=binomial())  
> xtable(m0Sex)
```

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.3418	0.1171	-11.46	0.0000
sexofeminino	0.5443	0.2067	2.63	0.0084

- $OR_{Sexo:Fem} = 1.72$

- $Sifilis \sim Sexo + faixaetaria$

```
> m1Sex <- glm(sifilis ~ sexo + faixaetaria,  
+              dados, family=binomial())  
> xtable(m1Sex)
```

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-2.0659	0.2463	-8.39	0.0000
sexofeminino	0.7422	0.2183	3.40	0.0007
faixaetaria25 a 34 anos	0.6171	0.2781	2.22	0.0265
faixaetaria35 a 49 anos	1.0353	0.2858	3.62	0.0003
faixaetaria50 anos ou mais	1.1607	0.3646	3.18	0.0015

- $OR_{Sexo:Fem} = 2.1$

- $Sifilis \sim Sexo + Idade$

```
> m2Sex <- glm(sifilis ~ sexo + idade,  
+             dados, family=binomial())  
> xtable(m2Sex)
```

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-2.5044	0.3490	-7.17	0.0000
sexofeminino	0.7342	0.2170	3.38	0.0007
idade	0.0329	0.0090	3.66	0.0003

- $OR_{Sexo:Fem} = 2.08$

	Df	Deviance	Resid. Df	Resid. Dev	Pr(>Chi)
NULL			604	659.34	
sexo	1	6.76	603	652.58	0.0093
faixaetaria	3	16.95	600	635.63	0.0007

- AIC

$$AIC = -2l(\hat{\beta}) + 2p$$

onde $-2l(\hat{\beta}) = Deviance$ é a deviance ou função desvio.

- R^2 ajustado

$$R^2_{adj} = 1 - \left(1 - \frac{(n-1) Deviance}{(n-p) Deviance_0} \right)$$

onde $Deviance_0$ é a deviance do modelo nulo (só com intercepto).

AIC e R^2 ajustado

```
> AIC(m0Sex, m1Sex, m2Sex)
```

	df	AIC
m0Sex	2	656.5810
m1Sex	5	645.6326
m2Sex	3	645.1537

```
> glmtoolbox::adjR2(m0Sex, m1Sex, m2Sex)
```

	Deviance	R-squared	df	adj.R-squared
m0Sex	652.5810	0.01025	2	0.00860
m1Sex	635.6326	0.03595	5	0.02952
m2Sex	639.1537	0.03061	3	0.02739

- Sexo e faixa etária não são colineares ($GVIF < 10$)

```
> car::vif( glm(sifilis ~ sexo + faixaetaria,  
+              dados, family=binomial()) )  
              GVIF Df GVIF^(1/(2*Df))  
sexo          1.08117  1      1.039793  
faixaetaria 1.08117  3      1.013092
```

Multicolinearidade: Idade e faixa etária juntos

```
> summary( glm(sifilis ~ sexo + idade + faixaetaria,  
+             dados, family=binomial()) )
```

```
Call:  
glm(formula = sifilis ~ sexo + idade + faixaetaria, family = binomial(),  
    data = dados)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-2.099655	0.674332	-3.114	0.001848	**
sexofeminino	0.742434	0.218369	3.400	0.000674	***
idade	0.001634	0.030354	0.054	0.957058	
faixaetaria25 a 34 anos	0.602956	0.382346	1.577	0.114798	
faixaetaria35 a 49 anos	1.002031	0.681217	1.471	0.141307	
faixaetaria50 anos ou mais	1.106114	1.077052	1.027	0.304429	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 659.34 on 604 degrees of freedom
Residual deviance: 635.63 on 599 degrees of freedom
AIC: 647.63

Number of Fisher Scoring iterations: 4

- Calculando o GVIF

```
> car::vif( glm(sifilis ~ sexo + idade + faixaetaria,  
+              dados, family=binomial()) )  
              GVIF Df GVIF^(1/(2*Df))  
sexo           1.081758 1          1.040076  
idade          11.487130 1          3.389267  
faixaetaria 11.532768 3          1.503104
```

	OR	2.5 %	97.5 %
Bruto	1.72	1.15	2.58
Ajustado por faixa etária	2.10	1.37	3.22
Ajustado por idade	2.08	1.36	3.19

Tabela: Efeito do sexo (Base: Masculino) no log da chance de infecção por sífilis

- A deviance é uma medida de bondade de ajuste.
- Hosmer e Lemeshow (1980) e Lemeshow e Hosmer (1982) propuseram uma medida de bondade de ajuste mais apropriada para dados binários.
- Ideia:
 - Particionar os possíveis valores de probabilidade em g grupos (Ex. decís).
 - Para cada grupo, contar quantos casos foram observados cujo valor predito deveria pertencer àquele grupo.
 - Dessa forma, tem-se um tabela $g \times 2$,
 - Se o valor predito representar as frequências das tabelas, então tem-se um bom modelo.

- Estatística de bondade de ajuste de Hosmer-Lemeshow, $\hat{C}$

$$\hat{C} = \sum_{k=1}^g \frac{(o_k - n'_k \bar{\pi}_k)^2}{n'_k \bar{\pi}_k (1 - \bar{\pi}_k)}$$

onde g é o número de grupos, n'_k número de observações no grupo k , o_k número de casos observados no grupo k , e $\bar{\pi}_k$ é média das probabilidade estimada no grupo k .

- $\hat{C} \rightarrow \chi^2_{g-2}$

Exemplo: Teste Hosmer-Lemeshow

Para o exemplo da sífilis, sexo e faixa etária geram 8 grupos, então $g = 8$

	Grupo	O_k	n'_k	$\hat{\theta}_k$	E_k
1	masculino : 18 a 24 anos	13	105	0.11	11.81
2	masculino : 25 a 34 anos	24	143	0.19	27.20
3	masculino : 35 a 49 anos	37	138	0.26	36.29
4	masculino : 50 anos ou mais	18	58	0.29	16.70
5	feminino : 18 a 24 anos	11	58	0.21	12.19
6	feminino : 25 a 34 anos	25	66	0.33	21.80
7	feminino : 35 a 49 anos	13	32	0.43	13.71
8	feminino : 50 anos ou mais	1	5	0.46	2.30

$$\hat{C} = 3.03 \rightarrow \text{p-valor} = 0.806$$

Teste Hosmer-Lemeshow no R

```
> glmtoolbox::hltest(m1Sex)
```

The Hosmer-Lemeshow goodness-of-fit test

Group	Size	Observed	Expected
1	105	13	11.808265
2	143	24	27.197188
3	58	11	12.191735
4	138	37	36.291221
5	58	18	16.703326
6	66	25	21.802812
7	32	13	13.708779
8	5	1	2.296674

Statistic = 3.02556

degrees of freedom = 6

p-value = 0.80563



FIOCRUZ

- Quais são as suposições?
 - Independência
- A análise de resíduos para dados binários não é tão natural quanto para outros tipos de variáveis.
- Como o desfecho assume somente dois valores, a visualização de padrões é mais difícil.
- Análises para procurar de pontos de alavanca e *outliers* continuam válidas.

- Leverage (pontos de alavanca): h_{ii} (*hatvalues(modelo)*)

$$H = X^T (X^T X)^{-1} X^T$$

Valores h_{ii} maiores que 2 ou 2 vezes p/n merecem uma olhada.

- Leave-one-out measures:
 - DFFIT: Diferença nos ajustes: $\hat{y}_i - \hat{y}_{i(-i)}$
 - DFBETA: Diferença no ajuste de cada coeficiente: $\hat{\beta}_k - \hat{\beta}_{k(-i)}$
 - Distância de Cook: Diferença no ajuste em todos coeficientes

Outliers: Medidas de influência

```
> summary(influence.measures(m1Sex))
```

Potentially influential observations of

```
glm(formula = sifilis ~ sexo + faixaetaria, family = binomial(), data
```

	dfb.1_	dfb.sxfrm	dfb.fa3a	dfb.fa4a	dfb.faom	dffit	cov.r	cook.d	hat
103	-0.05	0.12	0.01	0.02	0.16	0.21	1.03_*	0.01	0.03_*
104	0.05	-0.11	-0.01	-0.02	-0.14	-0.19	1.03_*	0.01	0.03_*
143	0.05	-0.11	-0.01	-0.02	-0.14	-0.19	1.03_*	0.01	0.03_*
384	0.05	-0.11	-0.01	-0.02	-0.14	-0.19	1.03_*	0.01	0.03_*
560	0.05	-0.11	-0.01	-0.02	-0.14	-0.19	1.03_*	0.01	0.03_*