

Lista 1: Modelos lineares

18/09/2026

1. O banco `CHESS_database_revise.csv` contém informação de 1666 adultos que participaram do estudo CHES (Comprehensive Intelligent Hypertension Management System). Este estudo avaliou uma intervenção digital multifacetada para o manejo da hipertensão na atenção primária.

O desfecho de interesse é pressão sistólica de 24h aos 12 meses (`avg_sbp_2`). e as seguintes variáveis explicativas:

- grupo (`group`: 2 = intervenção, 3 = controle),
- sexo (`gender`: 0 = feminino, 1 = masculino),
- faixa etária (`age_group`),
- IMC (`rand_bmi`).

```
library(tidyverse)

# abrindo o banco

chess <- read.csv("data/zhang_2026/CHESS_database_revise.csv") %>%
  janitor::clean_names() %>%
  mutate(
    group = as.factor(group),
    gender = as.factor(gender)
  ) %>%
  select(subjid, avg_sbp_2, group, gender, age_group, rand_bmi)
```

- 1.1. Realize a análise descritiva (tabela 1), incluindo gráficos do desfecho com as variáveis explicativas.

```
# grafico de barras
```

```
chess %>%
  ggplot(aes(x = group)) +
  geom_bar()
```

```
# histograma
```

```
hist(chess$avg_sbp_2)
```

```
# histograma
```

```
hist(chess$rand_bmi)
```

```
# grafico de barras
```

```
chess %>%
  ggplot(aes(x = gender)) +
  geom_bar()
```

```
# grafico de barras
```

```
chess %>%
  ggplot(aes(x = age_group)) +
  geom_bar()
```

```
# boxplot
```

```
chess %>%
  ggplot(aes(x = group, y = avg_sbp_2,
    fill = group)) +
  geom_boxplot()
```

```
# boxplot
```

```
chess %>%
  ggplot(aes(x = gender, y = avg_sbp_2,
    fill = group
  )
  ) +
  geom_boxplot()
```

```
# grafico de dispersao
```

```
chess %>%
  ggplot(aes(x = avg_sbp_2, y = rand_bmi,
    colour = group)) +
  geom_point()
```

```
# boxplot
```

```
chess %>%
  ggplot(aes(x = age_group, y = avg_sbp_2,
    fill = group)) +
  geom_boxplot()
```

1.2. Ajuste modelos lineares simples e múltiplos.

```
# modelos simples do desfecho para cada uma das variaveis explicativas
```

```
mod.1 <- lm(avg_sbp_2 ~ group, data = chess)
summary(mod.1)

mod.2 <- lm(avg_sbp_2 ~ age_group, data = chess)
summary(mod.2)

mod.3 <- lm(avg_sbp_2 ~ rand_bmi, data = chess)
summary(mod.3)

mod.4 <- lm(avg_sbp_2 ~ gender, data = chess)
summary(mod.4)
```

```
# modelos multiplos inserindo uma variavel por vez mas sempre mantendo
# a variavel grupo por se tratar de um ensaio clinico
```

```
mod.m1 <- lm(avg_sbp_2 ~ group + age_group, data = chess)
summary(mod.m1)
```

```
mod.m2 <- lm(avg_sbp_2 ~ group + age_group + rand_bmi, data = chess)
summary(mod.m2)

mod.m3 <- lm(avg_sbp_2 ~ group + age_group + rand_bmi + gender, data = chess)
summary(mod.m3)
```

1.3. Compare os modelos ajustados e justifique a escolha do modelo final (ex.: AIC, R^2 , ANOVA).

```
# comparando AIC de todos os modelos
```

```
AIC(mod.1, mod.2, mod.3, mod.4,
    mod.m1, mod.m2, mod.m3)
```

```
# comparando a insercao das variaveis. importante lembrar que os modelos
# comparados devem ser aninhados
```

```
anova(mod.1, mod.m1, mod.m2, mod.m3)
```

1.4. Realize a análise dos resíduos do modelo final e avalie a adequação das suposições do modelo (Normalidade, homocedasticidade e independência) e investigue a presença de observações influentes.

```
# avaliando os pressupostos de homocedasticidade e independencia
```

```
# verificar presenca de alguma forma nao linear; se os pontos estao distrubuidos
# ao longa da media; independencia
```

```
p.m3 = mod.m3$rank # Numero de parametros
```

```
res.m3 <- rstandard(mod.m3)
```

```
dados.m3 <- data.frame(
  res = res.m3,
  Ordem = 1:length(res.m3),
  Fit = mod.m3$fitted.values
)
```

```
ggplot(data = dados.m3, aes(x = Ordem, y = res)) +
  geom_point() +
  theme_bw(base_size = 18) +
  xlab("Ordem dos dados") +
  geom_hline(yintercept = c(-2, 2, 0), linetype = c(2, 2, 1)) +
  ylab("Resíduos padronizados - Modelo multiplo")
```

```
ggplot(data = dados.m3, aes(x = Fit, y = res)) +
  geom_point() +
  theme_bw(base_size = 18) +
  ylab("Resíduos padronizados") +
  geom_hline(yintercept = c(-2, 2, 0), linetype = c(2, 2, 1)) +
  xlab("Fitted values - Modelo multiplo")
```

```
# avaliando o pressuposto de normalidade
```

```
bbb <- shapiro.test(dados.m3$res)
```

```
qqnorm(dados.m3$res)
```

```

qqline(dados.m3$res)

text(
  x = 1,
  y = min(dados.m3$res),
  label = paste(
    bbb$method,
    ": p-value=",
    round(bbb$p.value, 3)
  )
)

hist(dados.m3$res, col = "red")

# avaliando outliers e pontos influentes

dados.m3 <- dados.m3 %>%
  mutate(
    hii = hatvalues(mod.m3),
    hipn = hii * nrow(dados.m3) / 2,
    dffits = dffits(mod.m3),
    Dcook = cooks.distance(mod.m3)
  )

ggplot(dados.m3, aes(x = Ordem, y = hipn)) +
  geom_point() +
  theme_bw(base_size = 18) +
  ylab(expression(h[ii]/(p/n))) +
  geom_hline(yintercept = c(2, 3), linetype = 1:2) +
  xlab("Data index")

ggplot(dados.m3, aes(x = Ordem, y = dffits)) +
  geom_point() +
  theme_bw(base_size = 18) +
  ylab("DFFITS") +
  geom_hline(
    yintercept = 2 * sqrt(p.m3 / length(mod.m3)),
    linetype = 2
  ) +
  xlab("Data index")

ggplot(dados.m3, aes(x=Ordem, y=Dcook)) +
  geom_point() +
  theme_bw(base_size = 18) +
  ylab("Cook's distance") +
  geom_hline(yintercept = qf(c(0.5, 0.75), df1 = p.m3,
                             df2 = length(res.m3)-p.m3), linetype = 2:3) +
  xlab("Data index")

# avaliando pontos influentes

```

```

summary(influence.measures(mod.m3))

teste.m3 <- influence.measures(mod.m3)

index.m3 <- which(
  apply(
    teste.m3$is.inf,
    1,
    FUN = function(x) any(x)
  )
)

ggplot(chess, aes(x = age_group, y = avg_sbp_2)) +
  geom_point(show.legend = FALSE) +
  geom_text(
    data = chess[index.m3, ] %>% rownames_to_column(),
    mapping = aes(label = rowname),
    color = "black",
    check_overlap = TRUE
  ) +
  theme_bw(base_size = 18)

ggplot(chess, aes(x = gender, y = avg_sbp_2)) +
  geom_point(show.legend = FALSE) +
  geom_text(
    data = chess[index.m3, ] %>% rownames_to_column(),
    mapping = aes(label = rowname),
    color = "black",
    check_overlap = TRUE
  ) +
  theme_bw(base_size = 18)

ggplot(chess, aes(x = rand_bmi, y = avg_sbp_2)) +
  geom_point(show.legend = FALSE) +
  geom_text(
    data = chess[index.m3, ] %>% rownames_to_column(),
    mapping = aes(label = rowname),
    color = "black",
    check_overlap = TRUE
  ) +
  theme_bw(base_size = 18)

ggplot(chess, aes(x = group, y = avg_sbp_2)) +
  geom_point(show.legend = FALSE) +
  geom_text(
    data = chess[index.m3, ] %>% rownames_to_column(),
    mapping = aes(label = rowname),
    color = "black",
    check_overlap = TRUE
  ) +
  theme_bw(base_size = 18)

```

1.5. Apresente e interprete os resultados do modelo final escolhido.