

Modelos Estatísticos I

Modelos para desfecho contínuo

Leo Bastos – leonardo.bastos@fiocruz.br

PROCC – Fundação Oswaldo Cruz

<https://github.com/lsbastos/eae2>

- 1 Modelo linear múltiplo
- 2 Análise de resíduos
- 3 Comparação de modelos
 - ANOVA
 - Critério de informação
- 4 Revisitando outros exemplos

O modelo linear múltiplo

- Vamos assumir que temos duas ou mais variáveis explicativas.
- Seja Y um desfecho contínuo avaliado em n observações independentes, e de forma geral p variáveis explicativas X , ou seja,

$$Y_i | X_i \sim N(\mu_i, \sigma^2), \quad i = 1, 2, \dots, n,$$
$$\mu_i = \alpha + \beta_1 X_{1,i} + \beta_2 X_{2,i} + \dots + \beta_p X_{p,i}.$$

- Isso é o mesmo que escrever

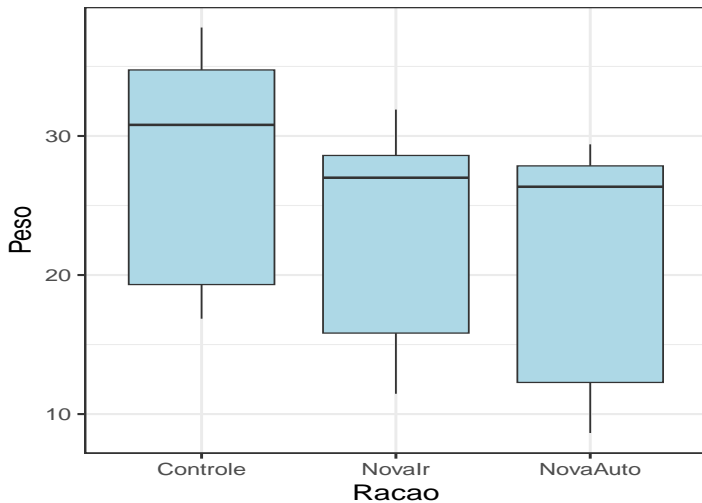
$$Y_i = \alpha + \beta_1 X_{1,i} + \beta_2 X_{2,i} + \dots + \beta_p X_{p,i} + \epsilon_i$$

onde $\epsilon_i \sim N(0, \sigma^2)$, e $\epsilon_i \perp \epsilon_j, \forall i \neq j$.

Exemplo do peso dos ratinhos

- Considere um estudo realizado para avaliar a eficiência de ração no ganho de peso de ratos.
- Seja Y peso (em g) de 45 ratos com 20 dias de idade alimentados a partir do desmame por duas semanas com uma das três marcas diferentes de ração.
- Os ratos também pertencem a 3 linhagens distintas.

Visualizando os dados




```
> summary(aov(Peso ~ Racao, data = racao))
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Racao	2	394	196.99	3.066	0.0574 .
Residuals	41	2634	64.25		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

1 observation deleted due to missingness

Visualizando os dados

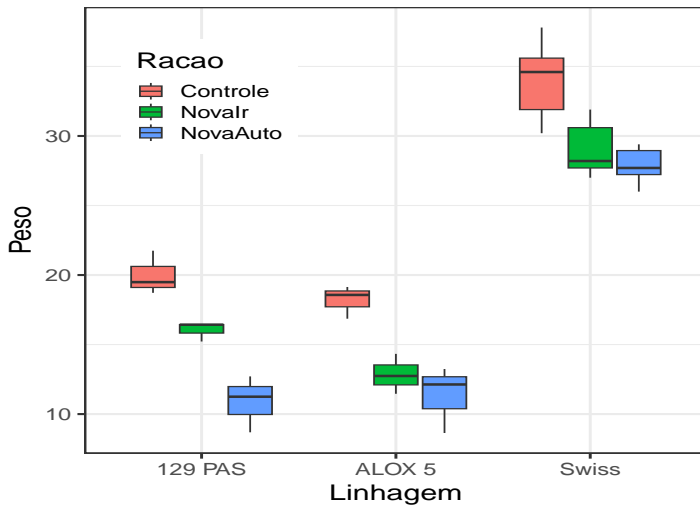


```
> summary(aov(Peso ~ Linhagem, data = racao))
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Linhagem	2	2531.1	1265.5	104.3	<2e-16 ***
Residuals	41	497.4	12.1		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
1 observation deleted due to missingness

Visualizando os dados



```
> summary(aov(Peso ~ Racao + Linhagem, data = racao))
```

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Racao	2	394.0	197.0	54.19	5.51e-12 ***
Linhagem	2	2492.7	1246.3	342.87	< 2e-16 ***
Residuals	39	141.8	3.6		

```
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
1 observation deleted due to missingness
```

- O modelo que incorpora a exposição e controla pela linhagem é dado por

$$Y_i \sim N(\mu_i, \sigma^2), \quad i = 1, \dots, 45,$$
$$\mu_i = \alpha + \beta_1 X_{1,i}^{(NovaAu)} + \beta_2 X_{1,i}^{(Novalr)} + \beta_3 X_{2,i}^{(ALOX5)} + \beta_4 X_{2,i}^{(Swiss)}$$

onde X_1 é o efeito da ração, e X_2 é o efeito da linhagem.

- A notação no R seria: *Peso* ~ *Racao* + *Linhagem*

O modelo no R

```
> modelo <- lm(Peso ~ Racao + Linhagem, data = racao)
> summary(modelo)
```

Call:

```
lm(formula = Peso ~ Racao + Linhagem, data = racao)
```

Residuals:

Min	1Q	Median	3Q	Max
-4.0292	-1.3412	0.1531	1.4275	3.7783

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	19.4941	0.7533	25.879	< 2e-16 ***
RacaoNovaIr	-4.8073	0.6962	-6.905	2.89e-08 ***
RacaoNovaAuto	-6.7749	0.7087	-9.560	9.02e-12 ***
LinhagemALOX 5	-1.5100	0.8988	-1.680	0.101
LinhagemSwiss	14.5277	0.7375	19.698	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.907 on 39 degrees of freedom

Em média

- os ratos da linha 129 PAS tratados com a ração controle pesam 19.5g.
- as duas rações, Nova Irradiada e Nova autoclavada, reduzem o peso médio em 4.8 e 6.8g respectivamente quando comparadas ao controle.
- a linhagem ALOX 5 não difere estatisticamente da 129 PAS. No entanto, a linhagem Swiss em média pesa 14.5g a mais que a 129 PAS.

- Quais forma as suposições assumidas para o modelo anterior?
 - Normalidade
 - Independência
 - Variância constante
- Será que elas são válidas?
- Como podemos checar?

- Vamos definir os resíduos do modelo como

$$e_i = Y_i - \hat{Y}_i$$

- Por construção, a distribuição dos resíduos é

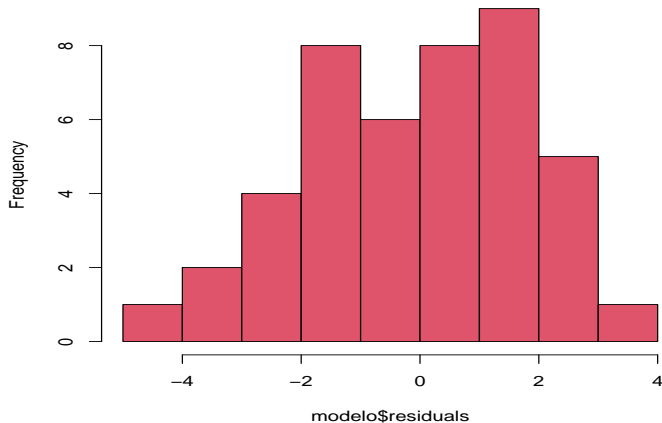
$$e_i \sim N(0, \sigma^2), \quad \forall i \quad e_i \perp e_j \forall i \neq j$$

- Podemos então olhar estatísticas descritivas dos resíduos

Suposição de normalidade


```
> hist(modelo$residuals, col = 2)
```

Histogram of modelo\$residuals



Suposição de normalidade

```
> qqnorm(modelo$residuals )
```



Podemos testar a hipótese de normalidade usando o teste de Shapiro-Wilks

$$\begin{cases} H_0 : & \text{as observações seguem uma distribuição normal}(\mu, \sigma^2) \\ H_1 : & \text{as observações seguem outra distribuição.} \end{cases}$$

```
> shapiro.test(modelo$residuals)
```

Shapiro-Wilk normality test


```
data: modelo$residuals
```

```
W = 0.9773, p-value = 0.5292
```

Variância constante (e padrões não-lineares)

Faz-se um scatter plot dos resíduos versus a ordem dos dados, e espera-se que a variância não tenha um padrão bem definido

```
> plot(modelo$residuals)
```



Análise de resíduos (resumo)

- A análise de resíduos consiste em um conjunto de estatísticas descritivas associadas aos resíduos de um modelo ajustado.
- A análise de resíduos deve ser realizada sempre que um modelo linear for ajustado e os coeficientes testados (teste de Wald $H_0 : \beta_k = 0$ versus $H_1 : \beta_k \neq 0$).
- As principais suposições de um modelo linear são
 - Normalidade (que pode ser relaxada se a amostra for grande)
 - Variância constante (Homocedasticidade)
 - Independência
- A análise de resíduos pode se estender ad infinitum, pois podemos testar a influencia de outras variáveis, formas não lineares, presença de outlier, etc. (Ler capítulos 7 e 8 do open statistics 3rd ed.)

Suponha agora que gostaríamos de ajustar diferentes modelos:

```
> modeloR <- lm(Peso ~ Racao, data = racao)
> modeloL <- lm(Peso ~ Linhagem, data = racao)
> modelo <- lm(Peso ~ Racao + Linhagem, data = racao)
> modeloRL <- lm(Peso ~ Racao * Linhagem, data = racao)
```

- Como podemos comparar diferentes modelos?
- Se os modelos forem aninhados* podemos usar a ANOVA no modelo mais completo
- Outra forma de comparar modelos é usando critérios de informação.

Testando a interação

No modelo mais completo temos o termo de interação *Racao : Linhagem*, podemos testar se algum dos termos da interação é significativo

```
> summary(modeloRL)
```

Call:

```
lm(formula = Peso ~ Racao * Linhagem, data = racao)
```

Residuals:

Min	1Q	Median	3Q	Max
-3.5889	-1.2083	0.1174	1.4931	4.0111

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	19.9867	1.0700	18.679	< 2e-16 ***
RacaoNovaIr	-3.9567	1.5132	-2.615	0.0131 *
RacaoNovaAuto	-9.1033	1.5132	-6.016	7.36e-07 ***
LinhagemALOX 5	-1.7967	1.5132	-1.187	0.2431
LinhagemSwiss	13.8022	1.2355	11.171	4.33e-13 ***
RacaoNovaIr:LinhagemALOX 5	-1.3900	2.1400	-0.650	0.5202
RacaoNovaAuto:LinhagemALOX 5	2.2500	2.1400	1.051	0.3003
RacaoNovaIr:LinhagemSwiss	-0.9544	1.7473	-0.546	0.5884
RacaoNovaAuto:LinhagemSwiss	3.2019	1.7609	1.818	0.0776 .

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.853 on 35 degrees of freedom



Testando a interação

Testando usando a ANOVA de modelos, partindo do modelo nulo até o modelo completo

```
> anova(modeloRL)
```

Analysis of Variance Table

Response: Peso

	Df	Sum Sq	Mean Sq	F value	Pr(>F)	
Racao	2	393.98	196.99	57.3526	9.006e-12	***
Linhagem	2	2492.67	1246.33	362.8666	< 2.2e-16	***
Racao:Linhagem	4	21.55	5.39	1.5688	0.2043	
Residuals	35	120.21	3.43			

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Cada linha testa a igualdade do modelo anterior (o primeiro é o modelo nulo, i.e. $Y \sim 1$) e o modelo com a adição da variável daquela linha.

Testando a interação

Note que a ordem de entrada das covariáveis do modelo é importante

```
> anova(lm(Peso ~ Linhagem*Racao, data = racao))
```

Analysis of Variance Table

Response: Peso

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Linhagem	2	2531.06	1265.53	368.4555	< 2.2e-16 ***
Racao	2	355.58	177.79	51.7637	3.502e-11 ***
Linhagem:Racao	4	21.55	5.39	1.5688	0.2043
Residuals	35	120.21	3.43		

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Dica: Se for usar esse recurso, inclua a sua exposição de interesse primeiro.

Podemos comparar dois modelos

```
> anova(modeloR, modeloRL)
```

Analysis of Variance Table

Model 1: $\text{Peso} \sim \text{Racao}$

Model 2: $\text{Peso} \sim \text{Racao} * \text{Linhagem}$

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	41	2634.43				
2	35	120.21	6	2514.2	122	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

- O método da ANOVA para comparar modelos funciona bem para comparar modelos lineares alinhados
- Uma abordagem mais geral, é baseada em **critérios de informação**
- Os critérios de informação são construídos a partir da função de desvio (*deviance*)
- Essa função é dada por $-2 \log_e \hat{L}$, \hat{L} é a verossimilhança ajustada
- Para o modelo linear a função desvio é dada por:

$$-2 \log_e \hat{L} = n \log(2\pi\hat{\sigma}^2) + \frac{1}{\hat{\sigma}^2} \sum_i (y_i - \hat{y}_i)^2$$

Critério de informação

- Se compararmos a função desvio de dois modelos com o mesmo tamanho de amostra, temos que aquele com o menor valor é o melhor ajustado.
- No entanto, modelos com muitos parâmetros acabam sendo beneficiados. (*overfitting*)
- O critério de informação mais famoso foi proposto por Akaike (1974)

$$AIC = 2p - 2 \log_e \hat{L}$$

onde p é o número de parâmetros

- Outro critério também popular é o BIC, proposto por Schwarz (1978)

$$BIC = p \log_e n - 2 \log_e \hat{L}$$

- Ambos critérios penalizam modelos com mais parâmetros

- Os critérios de informação apresentados estão implementados no R
- As funções associadas se aplicam ao objeto do modelo ajustado
- No exemplo:

```
> AIC(modelo)
```

```
[1] 188.3463
```

```
> BIC(modelo)
```

```
[1] 199.0515
```

Cr terios de informa  o no R

	df	AIC	BIC
modeloR	4.00	312.92	320.06
modeloL	4.00	239.57	246.71
modelo	6.00	188.35	199.05
modeloRL	10.00	189.09	206.93

- Seja uma amostra de 150 participantes do SHHS (Scottish Heart Health Study), e desejamos ver como o IMC depende do histórico de tabagismo e do sexo.
- O desfecho é será o IMC (kg/m^2), e as explicativas são sexo (duas categorias) e tabagismo (3 categorias)
- Teremos quatro modelos candidatos:
 - 1 IMC (Y) versus sexo ($X_1 = \{M, F\}$)
 - 2 IMC versus tabagismo ($X_2 = \{\text{current, ex, never}\}$)
 - 3 IMC versus sexo e tabagismo
 - 4 IMC versus sexo, tabagismo, e sua interação

Modelo 1

$$Y_i | X_i \sim N(\mu_i, \sigma^2), \quad i = 1, 2, \dots, 150, \quad Y_i \perp Y_j, \forall i \neq j, \\ \mu_i = \alpha + \beta_1 X_{1,i}^{(2)}.$$

onde $X_1^{(1)}$ é a categorias de referência de sexo.

```
> (modelo1.shhs <- lm(BMI ~ Sex, data = SHHS))
```

Call:

```
lm(formula = BMI ~ Sex, data = SHHS)
```

Coefficients:

(Intercept)	SexF
26.332	-1.112

$$Y_i | X_i \sim N(\mu_i, \sigma^2), \quad i = 1, 2, \dots, 150, \quad Y_i \perp Y_j, \forall i \neq j,$$
$$\mu_i = \alpha + \beta_2 X_{2,i}^{(2)} + \beta_3 X_{2,i}^{(3)}.$$

onde $X_2^{(1)}$ é a categoria de referência de tabagismo.

```
> (modelo2.shhs <- lm(BMI ~ Smoking, data = SHHS))
```

Call:

```
lm(formula = BMI ~ Smoking, data = SHHS)
```

Coefficients:

(Intercept)	Smokingex	Smokingnever
24.527	1.691	2.279

Modelo 3

$$Y_i | X_i \sim N(\mu_i, \sigma^2), \quad i = 1, 2, \dots, 150, \quad Y_i \perp Y_j, \forall i \neq j,$$
$$\mu_i = \alpha + \beta_1 X_{1,i}^{(2)} + \beta_2 X_{2,i}^{(2)} + \beta_3 X_{2,i}^{(3)}.$$

```
> (modelo3.shhs <- lm(BMI ~ Sex + Smoking, data = SHHS))
```

Call:

```
lm(formula = BMI ~ Sex + Smoking, data = SHHS)
```

Coefficients:

(Intercept)	SexF	Smokingex	Smokingnever
25.112	-1.340	1.655	2.483

Modelo 4

$$Y_i | X_i \sim N(\mu_i, \sigma^2), \quad i = 1, 2, \dots, 150, \quad Y_i \perp Y_j, \forall i \neq j,$$
$$\mu_i = \alpha + \beta_1 X_{1,i}^{(2)} + \beta_2 X_{2,i}^{(2)} + \beta_3 X_{2,i}^{(3)} + \beta_4 X_{1,i}^{(2)} X_{2,i}^{(2)} + \beta_5 X_{1,i}^{(2)} X_{2,i}^{(3)}.$$

```
> (modelo4.shhs <- lm(BMI ~ Sex * Smoking, data = SHHS))
```

Call:

```
lm(formula = BMI ~ Sex * Smoking, data = SHHS)
```

Coefficients:

(Intercept)	SexF	Smokingex	Smokingnever
25.5287	-2.2954	1.3009	1.3722
SexF:Smokingex	SexF:Smokingnever		
0.8008	2.1348		



Escolhendo modelo via ANOVA

```
> anova(modelo4.shhs)
```

Analysis of Variance Table

Response: BMI

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
Sex	1	46.28	46.279	4.2317	0.0414790 *
Smoking	2	167.76	83.880	7.6700	0.0006835 ***
Sex:Smoking	2	29.78	14.892	1.3617	0.2595062
Residuals	144	1574.81	10.936		


Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Escolhendo modelo via critérios de informação


	df	AIC	BIC
modelo1.shhs	3.00	802.10	811.13
modelo2.shhs	4.00	795.19	807.23
modelo3.shhs	5.00	791.18	806.23
modelo4.shhs	7.00	792.37	813.44

```
> hist(modelo3.shhs$residuals)
```

Histogram of modelo3.shhs\$residuals



```
> plot(modelo3.shhs$residuals)
```



Modelo final

```
> summary(modelo3.shhs)
```

Call:

```
lm(formula = BMI ~ Sex + Smoking, data = SHHS)
```

Residuals:

Min	1Q	Median	3Q	Max
-9.5618	-2.1509	-0.2218	1.9846	9.4236

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	25.1118	0.5071	49.522	< 2e-16 ***
SexF	-1.3400	0.5486	-2.443	0.015779 *
Smokingex	1.6545	0.6707	2.467	0.014785 *
Smokingnever	2.4829	0.6498	3.821	0.000196 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.315 on 146 degrees of freedom

Multiple R-squared: 0.1177, Adjusted R-squared: 0.0996

F-statistic: 6.492 on 3 and 146 DF, p-value: 0.0003737



Exemplo: DMFT


- DMFT versus consumo de açúcar e tipo de país

$$Y_i | X_i \sim N(\mu_i, \sigma^2), \quad i = 1, 2, \dots, n, \quad Y_i \perp Y_j, \forall i \neq j, \\ \mu_i = \alpha + \beta_1 X_{1,i} + \beta_2 X_{2,i}.$$

- $n = 90$ países
- X_1 é o consumo de açúcar (kg per capita / ano)
- X_2 é a classificação do país

$$X_2 = \begin{cases} 1 & \text{se país industrializado,} \\ 0 & \text{se país em desenvolvimento.} \end{cases}$$

Exemplo: DMFT versus consumo de açúcar



Quatro modelos distintos

- Modelo 1:

$$\mathbb{E}[DFMT] = \alpha + \beta_1 \text{Consumo}$$

- Modelo 2:

$$\mathbb{E}[DFMT] = \alpha + \beta_1 \text{Consumo} + \beta_2 \text{Pais}$$

- Modelo 3:

$$\mathbb{E}[DFMT] = \alpha + \beta_1 \text{Consumo} + \beta_3 \text{Consumo:Pais}$$


- Modelo 4:

$$\mathbb{E}[DFMT] = \alpha + \beta_1 \text{Consumo} + \beta_2 \text{Pais} + \beta_3 \text{Consumo:Pais}$$

Ajuste dos modelos no R

```
> # Modelo ignorando o tio de país
> modelo1 <- lm(DMFT ~ Consumo, data = dmft)
> #
> # Modelo variando intercepto
> modelo2 <- lm(DMFT ~ Consumo + Pais, data = dmft)
> #
> # Modelo variando slope
> modelo3 <- lm(DMFT ~ Consumo + Consumo:Pais,
+               data = dmft)
> #
> # Modelo variando intercepto e slope
> modelo4 <- lm(DMFT ~ Consumo + Pais + Consumo:Pais,
+               data = dmft)
```

Modelo 1



Modelo 1

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.2966	0.3062	4.23	0.0001
Consumo	0.0451	0.0089	5.06	0.0000


```
> AIC(modelo1)
```

```
[1] 319.3474
```

```
> BIC(modelo1)
```

```
[1] 326.8468
```

Modelo 2



Modelo 2

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.6774	0.4998	3.36	0.0012
Consumo	0.0403	0.0102	3.94	0.0002
PaisEm desenvolvimento	-0.3479	0.3608	-0.96	0.3375


```
> AIC(modelo2)
```

```
[1] 320.3903
```

```
> BIC(modelo2)
```

```
[1] 330.3895
```


Modelo 3



Modelo 3

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.3211	0.3129	4.22	0.0001
Consumo	0.0464	0.0094	4.92	0.0000
Consumo:PaisEm desenvolvimento	-0.0038	0.0087	-0.43	0.6680


```
> AIC(modelo3)
```

```
[1] 321.156
```

```
> BIC(modelo3)
```

```
[1] 331.1552
```

Modelo 4



Modelo 4

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	3.9086	1.2865	3.04	0.0032
Consumo	-0.0131	0.0301	-0.43	0.6658
PaisEm desenvolvimento	-2.7439	1.3248	-2.07	0.0413
Consumo:PaisEm desenvolvimento	0.0600	0.0320	1.88	0.0638

```
> AIC(modelo4)
```


```
[1] 318.7751
```


```
> BIC(modelo4)
```

```
[1] 331.2742
```


Análise de resíduos do Modelo 4

Histogram of modelo4\$residuals





Análise de resíduos



Quatro modelos distintos na escala do log

- Modelo 1:

$$\log(\mathbb{E}[DFMT]) = \alpha + \beta_1 \text{Consumo}$$

- Modelo 2:

$$\log(\mathbb{E}[DFMT]) = \alpha + \beta_1 \text{Consumo} + \beta_2 \text{Pais}$$

- Modelo 3:

$$\log(\mathbb{E}[DFMT]) = \alpha + \beta_1 \text{Consumo} + \beta_3 \text{Consumo:Pais}$$

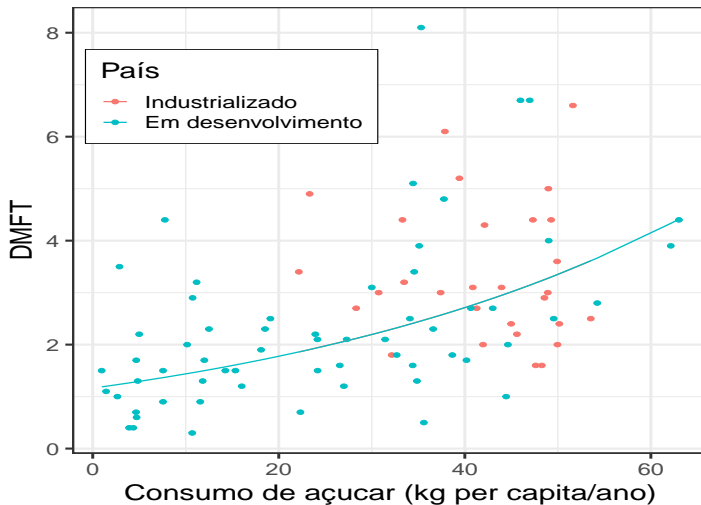
- Modelo 4:

$$\log(\mathbb{E}[DFMT]) = \alpha + \beta_1 \text{Consumo} + \beta_2 \text{Pais} + \beta_3 \text{Consumo:Pais}$$

Ajuste dos modelos no R

```
> # Modelo ignorando o tio de país
> modelo1 <- lm(log(DMFT) ~ Consumo, data = dmft)
> #
> # Modelo variando intercepto
> modelo2 <- lm(log(DMFT) ~ Consumo + Pais, data = dmft)
> #
> # Modelo variando slope
> modelo3 <- lm(log(DMFT) ~ Consumo + Consumo:Pais,
+               data = dmft)
> #
> # Modelo variando intercepto e slope
> modelo4 <- lm(log(DMFT) ~ Consumo + Pais + Consumo:Pais,
+               data = dmft)
```

Modelo 1



Modelo 1

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.1511	0.1229	1.23	0.2221
Consumo	0.0212	0.0036	5.92	0.0000


```
> AIC(modelo1)
```

```
[1] 155.0517
```

```
> BIC(modelo1)
```

```
[1] 162.5512
```

Modelo 2



Modelo 2

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.3736	0.1994	1.87	0.0644
Consumo	0.0184	0.0041	4.50	0.0000
PaisEm desenvolvimento	-0.2032	0.1439	-1.41	0.1616


```
> AIC(modelo2)
```

```
[1] 155.0132
```

```
> BIC(modelo2)
```

```
[1] 165.0125
```

Modelo 3



Modelo 3

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	0.1691	0.1253	1.35	0.1806
Consumo	0.0221	0.0038	5.85	0.0000
Consumo:PaisEm desenvolvimento	-0.0028	0.0035	-0.79	0.4327


```
> AIC(modelo3)
```

```
[1] 156.4114
```

```
> BIC(modelo3)
```

```
[1] 166.4106
```

Modelo 4



Modelo 4

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.3871	0.5102	2.72	0.0079
Consumo	-0.0059	0.0120	-0.49	0.6241
PaisEm desenvolvimento	-1.2916	0.5254	-2.46	0.0160
Consumo:PaisEm desenvolvimento	0.0273	0.0127	2.15	0.0343

```
> AIC(modelo4)
```


```
[1] 152.2993
```

```
> BIC(modelo4)
```


```
[1] 164.7983
```

Análise de resíduos do Modelo 1


Histogram of modelo4\$residuals



Análise de resíduos



Melhorou?



- Análise de resíduos do modelo linear
 - Normalidade (histograma ou qqplot dos resíduos)
 - Independência (resíduos versus ordem dos dados)
 - Variância constante (resíduos versus ordem dos dados)
- Comparação de modelos
 - ANOVA
 - Critérios de informação
- Aula prática
 - Replicar os exemplos da aula e outros
 - Veremos métodos de seleção de variáveis