

Estatística aplicada à epidemiologia II

Modelo logístico

Leo Bastos – leonardo.bastos@fiocruz.br

PROCC – Fundação Oswaldo Cruz

<https://github.com/lsbastos/eae2>



1 Revisitando o modelo logístico

2 Bondade de ajuste

3 Análise de resíduos



FIOCRUZ

Regressão logística múltipla

- O modelo logístico ~~multivariado~~ múltiplo
- Seja Y um desfecho binário, e $X_1, X_2, \dots, X_p$, p variáveis explicativas.
- O modelo de regressão logística é dado por

$$Y_i \sim \text{Bernoulli}(\theta_i)$$

onde

$$\text{logit}(\theta_i) = \alpha + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_p X_{pi}$$

- Exponencial dos coeficientes pode ser interpretado como razão de chances da variável associada ao coeficiente fixada todas as outras em um mesmo valores (independente qual for esse valor).



FIOCRUZ

Regressão logística múltipla

- O modelo logístico multivariado múltiplo
- Seja Y um desfecho binário, e $X_1, X_2, \dots, X_p$, p variáveis explicativas.
- O modelo de regressão logística é dado por

$$Y_i \sim \text{Bernoulli}(\theta_i)$$

onde

$$\text{logit}(\theta_i) = \alpha + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_p X_{pi}$$

- Exponencial dos coeficientes pode ser interpretado como razão de chances da variável associada ao coeficiente fixada todas as outras em um mesmo valores (independente qual for esse valor).



FIOCRUZ

Regressão logística múltipla

- O modelo logístico ~~multivariado~~ múltiplo
- Seja Y um desfecho binário, e $X_1, X_2, \dots, X_p$, p variáveis explicativas.
- O modelo de regressão logística é dado por

$$Y_i \sim \text{Bernoulli}(\theta_i)$$

onde

$$\text{logit}(\theta_i) = \alpha + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_p X_{pi}$$

- Exponencial dos coeficientes pode ser interpretado como razão de chances da variável associada ao coeficiente fixada todas as outras em um mesmo valores (independente qual for esse valor).



FIOCRUZ

Regressão logística múltipla

- O modelo logístico multivariado múltiplo
- Seja Y um desfecho binário, e $X_1, X_2, \dots, X_p$, p variáveis explicativas.
- O modelo de regressão logística é dado por

$$Y_i \sim \text{Bernoulli}(\theta_i)$$

onde

$$\text{logit}(\theta_i) = \alpha + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_p X_{pi}$$

- Exponencial dos coeficientes pode ser interpretado como razão de chances da variável associada ao coeficiente fixada todas as outras em um mesmo valores (independente qual for esse valor).



FIOCRUZ

A função de ligação *logit*

- Função *logit*

$$\log\left(\frac{\theta_i}{1 - \theta_i}\right) = \mathbf{x}_i^T \boldsymbol{\beta} = \eta_i \Rightarrow \mu_i = \frac{e^{\eta_i}}{1 + e^{\eta_i}}$$

- Suponha que dois cenários serão comparados, onde a única diferença entre eles é a variável x_k , que assume valor a em um cenário e b no outro.

$$\log\left(\frac{\theta_{(x_k=a)}}{1 - \theta_{(x_k=a)}}\right) = \mathbf{x}_{-k}^T \boldsymbol{\beta}_k + a\beta_k \Rightarrow \frac{\theta_{(x_k=a)}}{1 - \theta_{(x_k=a)}} = \exp\{\mathbf{x}_{-k}^T \boldsymbol{\beta}_k + a\beta_k\}$$

- Logo a razão de chances de interesse é

$$OR = \frac{\frac{\theta_{(x_k=a)}}{1 - \theta_{(x_k=a)}}}{\frac{\theta_{(x_k=b)}}{1 - \theta_{(x_k=b)}}} = \frac{\exp\{\mathbf{x}_{-k}^T \boldsymbol{\beta}_k + a\beta_k\}}{\exp\{\mathbf{x}_{-k}^T \boldsymbol{\beta}_k + b\beta_k\}} = \exp\{\beta_k(a - b)\}$$

- Se $a = 1$ e $b = 0$ então

$$OR = \exp\{\beta_1\}$$



FIOCRUZ

A função de ligação *logit*

- Função *logit*

$$\log\left(\frac{\theta_i}{1 - \theta_i}\right) = \mathbf{x}_i^T \boldsymbol{\beta} = \eta_i \Rightarrow \mu_i = \frac{e^{\eta_i}}{1 + e^{\eta_i}}$$

- Suponha que dois cenários serão comparados, onde a única diferença entre eles é a variável x_k , que assume valor a em um cenário e b no outro.

$$\log\left(\frac{\theta_{(x_k=a)}}{1 - \theta_{(x_k=a)}}\right) = \mathbf{x}_{-k}^T \boldsymbol{\beta}_k + x \beta_k \Rightarrow \frac{\theta_{(x_k=a)}}{1 - \theta_{(x_k=a)}} = \exp\{\mathbf{x}_{-k}^T \boldsymbol{\beta}_k + x \beta_k\}$$

- Logo a razão de chances de interesse é

$$OR = \frac{\frac{\theta_{(x_k=a)}}{1 - \theta_{(x_k=a)}}}{\frac{\theta_{(x_k=b)}}{1 - \theta_{(x_k=b)}}} = \frac{\exp\{\mathbf{x}_{-k}^T \boldsymbol{\beta}_k + a \beta_k\}}{\exp\{\mathbf{x}_{-k}^T \boldsymbol{\beta}_k + b \beta_k\}} = \exp\{\beta_k(a - b)\}$$

- Se $a = 1$ e $b = 0$ então

$$OR = \exp\{\beta_1\}$$



FIOCRUZ

A função de ligação *logit*

- Função *logit*

$$\log\left(\frac{\theta_i}{1 - \theta_i}\right) = \mathbf{x}_i^T \boldsymbol{\beta} = \eta_i \Rightarrow \mu_i = \frac{e^{\eta_i}}{1 + e^{\eta_i}}$$

- Suponha que dois cenários serão comparados, onde a única diferença entre eles é a variável x_k , que assume valor a em um cenário e b no outro.

$$\log\left(\frac{\theta_{(x_k=a)}}{1 - \theta_{(x_k=a)}}\right) = \mathbf{x}_{-k}^T \boldsymbol{\beta}_k + a\beta_k \Rightarrow \frac{\theta_{(x_k=a)}}{1 - \theta_{(x_k=a)}} = \exp\{\mathbf{x}_{-k}^T \boldsymbol{\beta}_k + a\beta_k\}$$

- Logo a razão de chances de interesse é

$$OR = \frac{\frac{\theta_{(x_k=a)}}{1 - \theta_{(x_k=a)}}}{\frac{\theta_{(x_k=b)}}{1 - \theta_{(x_k=b)}}} = \frac{\exp\{\mathbf{x}_{-k}^T \boldsymbol{\beta}_k + a\beta_k\}}{\exp\{\mathbf{x}_{-k}^T \boldsymbol{\beta}_k + b\beta_k\}} = \exp\{\beta_k(a - b)\}$$

- Se $a = 1$ e $b = 0$ então

$$OR = \exp\{\beta_1\}$$



FIOCRUZ

A função de ligação *logit*

- Função *logit*

$$\log\left(\frac{\theta_i}{1 - \theta_i}\right) = \mathbf{x}_i^T \boldsymbol{\beta} = \eta_i \Rightarrow \mu_i = \frac{e^{\eta_i}}{1 + e^{\eta_i}}$$

- Suponha que dois cenários serão comparados, onde a única diferença entre eles é a variável x_k , que assume valor a em um cenário e b no outro.

$$\log\left(\frac{\theta_{(x_k=a)}}{1 - \theta_{(x_k=a)}}\right) = \mathbf{x}_{-k}^T \boldsymbol{\beta}_k + a\beta_k \Rightarrow \frac{\theta_{(x_k=a)}}{1 - \theta_{(x_k=a)}} = \exp\{\mathbf{x}_{-k}^T \boldsymbol{\beta}_k + a\beta_k\}$$

- Logo a razão de chances de interesse é

$$OR = \frac{\frac{\theta_{(x_k=a)}}{1 - \theta_{(x_k=a)}}}{\frac{\theta_{(x_k=b)}}{1 - \theta_{(x_k=b)}}} = \frac{\exp\{\mathbf{x}_{-k}^T \boldsymbol{\beta}_k + a\beta_k\}}{\exp\{\mathbf{x}_{-k}^T \boldsymbol{\beta}_k + b\beta_k\}} = \exp\{\beta_k(a - b)\}$$

- Se $a = 1$ e $b = 0$ então

$$OR = \exp\{\beta_1\}$$



FIOCRUZ

Exemplo: Sífilis em usuários de drogas

- Seja um estudo transversal que recrutou aleatoriamente 605 usuários de drogas (heavy drug users)
- Heavy drug user: É aquele usuário que: usou droga injetável nos últimos 6 meses e/ou usou droga da pasta base da cocaína pelo menos 25 vezes nos últimos 6 meses.
- Tem-se o interesse em quantificar, entre outras coisas, a associação entre a infecção de sífilis com sexo e idade dos participantes do estudo.



FIOCRUZ

Exemplo: Sífilis em usuários de drogas

- Seja um estudo transversal que recrutou aleatoriamente 605 usuários de drogas (heavy drug users)
- Heavy drug user: É aquele usuário que: usou droga injetável nos últimos 6 meses e/ou usou droga da pasta base da cocaína pelo menos 25 vezes nos últimos 6 meses.
- Tem-se o interesse em quantificar, entre outras coisas, a associação entre a infecção de sífilis com sexo e idade dos participantes do estudo.



FIOCRUZ

Exemplo: Sífilis em usuários de drogas

- Seja um estudo transversal que recrutou aleatoriamente 605 usuários de drogas (heavy drug users)
- Heavy drug user: É aquele usuário que: usou droga injetável nos últimos 6 meses e/ou usou droga da pasta base da cocaína pelo menos 25 vezes nos últimos 6 meses.
- Tem-se o interesse em quantificar, entre outras coisas, a associação entre a infecção de sífilis com sexo e idade dos participantes do estudo.



FIOCRUZ

Exemplo: Sífilis em usuários de drogas

```
> # dados <- read.csv("Aula6_binary/DUsifilis.csv")  
> dados <- read.csv("../dados/DUsifilis.csv")  
> head(dados)
```

	sifilis	sexo	idade	faixaetaria
1	0	masculino	46	35 a 49 anos
2	0	masculino	29	25 a 34 anos
3	0	masculino	44	35 a 49 anos
4	0	masculino	20	18 a 24 anos
5	0	masculino	26	25 a 34 anos
6	0	masculino	39	35 a 49 anos



FIOCRUZ

- *Sifilis* $\sim$ *Sexo*

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.7975	0.1703	-4.68	0.0000
sexomascullino	-0.5443	0.2067	-2.63	0.0084

- $OR_{Sexo:Masculino} = 0.58$. (Qual a interpretação?)



- $Sifilis \sim Sexo$

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-0.7975	0.1703	-4.68	0.0000
sexomasculino	-0.5443	0.2067	-2.63	0.0084

- $OR_{Sexo:Masculino} = 0.58$. (Qual a interpretação?)



Mudando a referência

- Eu gostaria de interpretar como aumento na OR, olhar a OR com a mulher no numerador.
- Solução rápida, inverter o sinal do β . Pois $OR_{Sexo:Masculino} = 1/OR_{Sexo:Feminino}$ (É mesmo?)
- E portanto, $OR_{Sexo:Feminino} = 1/OR_{Sexo:Masculino} = 1/e^{\beta} = e^{-\beta}$
- No exemplo: $OR_{Sexo:Feminino} = 1/OR_{Sexo:Masculino} = 1.72$
- Um outro caminho, mudar a categoria de base no R usando a função `relevel()`.



FIOCRUZ

Mudando a referência

- Eu gostaria de interpretar como aumento na OR, olhar a OR com a mulher no numerador.
- Solução rápida, inverter o sinal do β . Pois
$$OR_{Sexo:Masculino} = 1/OR_{Sexo:Feminino} \text{ (É mesmo?)}$$
- E portanto, $OR_{Sexo:Feminino} = 1/OR_{Sexo:Masculino} = 1/e^{\beta} = e^{-\beta}$
- No exemplo: $OR_{Sexo:Feminino} = 1/OR_{Sexo:Masculino} = 1.72$
- Um outro caminho, mudar a categoria de base no R usando a função `relevel()`.



FIOCRUZ

Mudando a referência

- Eu gostaria de interpretar como aumento na OR, olhar a OR com a mulher no numerador.
- Solução rápida, inverter o sinal do β . Pois
 $OR_{Sexo:Masculino} = 1/OR_{Sexo:Feminino}$ (É mesmo?)
- E portanto, $OR_{Sexo:Feminino} = 1/OR_{Sexo:Masculino} = 1/e^{\beta} = e^{-\beta}$
- No exemplo: $OR_{Sexo:Feminino} = 1/OR_{Sexo:Masculino} = 1.72$
- Um outro caminho, mudar a categoria de base no R usando a função `relevel()`.



FIOCRUZ

Mudando a referência

- Eu gostaria de interpretar como aumento na OR, olhar a OR com a mulher no numerador.
- Solução rápida, inverter o sinal do β . Pois
 $OR_{Sexo:Masculino} = 1/OR_{Sexo:Feminino}$ (É mesmo?)
- E portanto, $OR_{Sexo:Feminino} = 1/OR_{Sexo:Masculino} = 1/e^{\beta} = e^{-\beta}$
- No exemplo: $OR_{Sexo:Feminino} = 1/OR_{Sexo:Masculino} = 1.72$
- Um outro caminho, mudar a categoria de base no R usando a função `relevel()`.



FIOCRUZ

Mudando a referência

- Eu gostaria de interpretar como aumento na OR, olhar a OR com a mulher no numerador.
- Solução rápida, inverter o sinal do β . Pois
 $OR_{Sexo:Masculino} = 1/OR_{Sexo:Feminino}$ (É mesmo?)
- E portanto, $OR_{Sexo:Feminino} = 1/OR_{Sexo:Masculino} = 1/e^{\beta} = e^{-\beta}$
- No exemplo: $OR_{Sexo:Feminino} = 1/OR_{Sexo:Masculino} = 1.72$
- Um outro caminho, mudar a categoria de base no R usando a função `relevel()`.



FIOCRUZ

Mudando a categoria de base

- $Sifilis \sim Sexo + Idade$

```
> dados$sexo = relevel(factor(dados$sexo),  
+                             ref = "masculino")  
> m0Sex <- glm(sifilis ~ sexo,  
+              dados, family=binomial())  
> xtable(m0Sex)
```

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.3418	0.1171	-11.46	0.0000
sexofeminino	0.5443	0.2067	2.63	0.0084

- $OR_{Sexo:Fem} = 1.72$



FIOCRUZ

Controlando pela idade

- $Sifilis \sim Sexo + faixaetaria$

```
> m1Sex <- glm(sifilis ~ sexo + faixaetaria,  
+             dados, family=binomial())  
> xtable(m1Sex)
```

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-2.0659	0.2463	-8.39	0.0000
sexofeminino	0.7422	0.2183	3.40	0.0007
faixaetaria25 a 34 anos	0.6171	0.2781	2.22	0.0265
faixaetaria35 a 49 anos	1.0353	0.2858	3.62	0.0003
faixaetaria50 anos ou mais	1.1607	0.3646	3.18	0.0015

- $OR_{Sexo:Fem} = 2.1$

- $Sifilis \sim Sexo + Idade$

```
> m2Sex <- glm(sifilis ~ sexo + idade,  
+             dados, family=binomial())  
> xtable(m2Sex)
```

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-2.5044	0.3490	-7.17	0.0000
sexofeminino	0.7342	0.2170	3.38	0.0007
idade	0.0329	0.0090	3.66	0.0003

- $OR_{Sexo:Fem} = 2.08$

Análise da deviance

	Df	Deviance	Resid. Df	Resid. Dev	Pr(>Chi)
NULL			604	659.34	
sexo	1	6.76	603	652.58	0.0093
faixaetaria	3	16.95	600	635.63	0.0007

- AIC

$$AIC = -2l(\hat{\beta}) + 2p$$

onde $-2l(\hat{\beta}) = Deviance$ é a deviance ou função desvio.

- R^2 ajustado

$$R_{adj}^2 = 1 - \left(1 - \frac{(n-1) Deviance}{(n-p) Deviance_0} \right)$$

onde $Deviance_0$ é a deviance do modelo nulo (só com intercepto).



- AIC

$$AIC = -2l(\hat{\beta}) + 2p$$

onde $-2l(\hat{\beta}) = Deviance$ é a deviance ou função desvio.

- R^2 ajustado

$$R_{adj}^2 = 1 - \left(1 - \frac{(n-1) Deviance}{(n-p) Deviance_0} \right)$$

onde $Deviance_0$ é a deviance do modelo nulo (só com intercepto).



AIC e R^2 ajustado

```
> AIC(m0Sex, m1Sex, m2Sex)
```

	df	AIC
m0Sex	2	656.5810
m1Sex	5	645.6326
m2Sex	3	645.1537

```
> glmtoolbox::adjR2(m0Sex, m1Sex, m2Sex)
```

	Deviance	R-squared	df	adj.R-squared
m0Sex	652.5810	0.01025	2	0.00860
m1Sex	635.6326	0.03595	5	0.02952
m2Sex	639.1537	0.03061	3	0.02739



FIOCRUZ

- Sexo e faixa etária não são colineares ($GVIF < 10$)

```
> car::vif( glm(sifilis ~ sexo + faixaetaria,  
+              dados, family=binomial()) )  
              GVIF Df GVIF^(1/(2*Df))  
sexo          1.08117  1      1.039793  
faixaetaria 1.08117  3      1.013092
```



Multicolinearidade: Idade e faixa etária juntos

```
> summary( glm(sifilis ~ sexo + idade + faixaetaria,  
+             dados, family=binomial()) )
```

```
Call:  
glm(formula = sifilis ~ sexo + idade + faixaetaria, family = binomial(),  
     data = dados)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-2.099655	0.674332	-3.114	0.001848	**
sexofeminino	0.742434	0.218369	3.400	0.000674	***
idade	0.001634	0.030354	0.054	0.957058	
faixaetaria25 a 34 anos	0.602956	0.382346	1.577	0.114798	
faixaetaria35 a 49 anos	1.002031	0.681217	1.471	0.141307	
faixaetaria50 anos ou mais	1.106114	1.077052	1.027	0.304429	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 659.34 on 604 degrees of freedom
Residual deviance: 635.63 on 599 degrees of freedom
AIC: 647.63

Number of Fisher Scoring iterations: 4

- Calculando o GVIF

```
> car::vif( glm(sifilis ~ sexo + idade + faixaetaria,  
+             dados, family=binomial()) )  
              GVIF Df GVIF^(1/(2*Df))  
sexo           1.081758 1          1.040076  
idade          11.487130 1          3.389267  
faixaetaria 11.532768 3          1.503104
```



	OR	2.5 %	97.5 %
Bruto	1.72	1.15	2.58
Ajustado por faixa etária	2.10	1.37	3.22
Ajustado por idade	2.08	1.36	3.19

Tabela: Efeito do sexo (Base: Masculino) no log da chance de infecção por sífilis

- 1 Revisitando o modelo logístico
- 2 Bondade de ajuste
- 3 Análise de resíduos



- A deviance é uma medida de bondade de ajuste.
- Hosmer e Lemeshow (1980) e Lemeshow e Hosmer (1982) propuseram uma medida de bondade de ajuste mais apropriada para dados binários.
- Ideia:

1. Particionar os possíveis valores de probabilidade em g grupos (Ex: 10 deslizes).

2. Para cada grupo, definir quantos casos foram observados cujo valor predito deveria pertencer aquele grupo.

3. Para cada grupo, gerar um teste de χ^2 para a hipótese de que:

- Se o valor predito representar as frequências das tabelas, então temos um bom modelo.



FIOCRUZ

- A deviance é uma medida de bondade de ajuste.
- Hosmer e Lemeshow (1980) e Lemeshow e Hosmer (1982) propuseram uma medida de bondade de ajuste mais apropriada para dados binários.
- Ideia:

- Particionar os possíveis valores de probabilidade em g grupos (Ex: decís)

Para cada grupo, calcular a probabilidade esperada de ocorrência de cada evento, usando a fórmula de probabilidade esperada para cada grupo.

- Se o valor médio observado for diferente das probabilidades esperadas, há uma má adaptação.



FIOCRUZ

- A deviance é uma medida de bondade de ajuste.
- Hosmer e Lemeshow (1980) e Lemeshow e Hosmer (1982) propuseram uma medida de bondade de ajuste mais apropriada para dados binários.
- Ideia:
 - Particionar os possíveis valores de probabilidade em g grupos (Ex. decis).
 - Para cada grupo, contar quantos casos foram observados cujo valor predito deveria pertencer àquele grupo.
 - Dessa forma, tem-se um tabela $g \times 2$.
 - Se o valor predito representar as frequências das tabelas, então tem-se um bom modelo.



FIOCRUZ

- A deviance é uma medida de bondade de ajuste.
- Hosmer e Lemeshow (1980) e Lemeshow e Hosmer (1982) propuseram uma medida de bondade de ajuste mais apropriada para dados binários.
- Ideia:
 - Particionar os possíveis valores de probabilidade em g grupos (Ex. decís).
 - Para cada grupo, contar quantos casos foram observados cujo valor predito deveria pertencer àquele grupo.
 - Dessa forma, tem-se um tabela $g \times 2$,
 - Se o valor predito representar as frequências das tabelas, então tem-se um bom modelo.



FIOCRUZ

- A deviance é uma medida de bondade de ajuste.
- Hosmer e Lemeshow (1980) e Lemeshow e Hosmer (1982) propuseram uma medida de bondade de ajuste mais apropriada para dados binários.
- Ideia:
 - Particionar os possíveis valores de probabilidade em g grupos (Ex. decís).
 - Para cada grupo, contar quantos casos foram observados cujo valor predito deveria pertencer àquele grupo.
 - Dessa forma, tem-se um tabela $g \times 2$,
 - Se o valor predito representar as frequências das tabelas, então tem-se um bom modelo.



FIOCRUZ

- A deviance é uma medida de bondade de ajuste.
- Hosmer e Lemeshow (1980) e Lemeshow e Hosmer (1982) propuseram uma medida de bondade de ajuste mais apropriada para dados binários.
- Ideia:
 - Particionar os possíveis valores de probabilidade em g grupos (Ex. decís).
 - Para cada grupo, contar quantos casos foram observados cujo valor predito deveria pertencer àquele grupo.
 - Dessa forma, tem-se um tabela $g \times 2$,
 - Se o valor predito representar as frequências das tabelas, então tem-se um bom modelo.



FIOCRUZ

- A deviance é uma medida de bondade de ajuste.
- Hosmer e Lemeshow (1980) e Lemeshow e Hosmer (1982) propuseram uma medida de bondade de ajuste mais apropriada para dados binários.
- Ideia:
 - Particionar os possíveis valores de probabilidade em g grupos (Ex. decís).
 - Para cada grupo, contar quantos casos foram observados cujo valor predito deveria pertencer àquele grupo.
 - Dessa forma, tem-se um tabela $g \times 2$,
 - Se o valor predito representar as frequências das tabelas, então tem-se um bom modelo.



- Estatística de bondade de ajuste de Hosmer-Lemeshow, $\hat{C}$

$$\hat{C} = \sum_{k=1}^g \frac{(o_k - n'_k \bar{\pi}_k)^2}{n'_k \bar{\pi}_k (1 - \bar{\pi}_k)}$$

onde g é o número de grupos, n'_k número de observações no grupo k , o_k número de casos observados no grupo k , e $\bar{\pi}_k$ é média das probabilidade estimada no grupo k .

- $\hat{C} \rightarrow \chi^2_{g-2}$



- Estatística de bondade de ajuste de Hosmer-Lemeshow, $\hat{C}$

$$\hat{C} = \sum_{k=1}^g \frac{(o_k - n'_k \bar{\pi}_k)^2}{n'_k \bar{\pi}_k (1 - \bar{\pi}_k)}$$

onde g é o número de grupos, n'_k número de observações no grupo k , o_k número de casos observados no grupo k , e $\bar{\pi}_k$ é média das probabilidade estimada no grupo k .

- $\hat{C} \rightarrow \chi^2_{g-2}$



Exemplo: Teste Hosmer-Lemeshow

Para o exemplo da sífilis, sexo e faixa etária geram 8 grupos, então $g = 8$

	Grupo	O_k	n'_k	$\hat{\theta}_k$	E_k
1	masculino : 18 a 24 anos	13	105	0.11	11.81
2	masculino : 25 a 34 anos	24	143	0.19	27.20
3	masculino : 35 a 49 anos	37	138	0.26	36.29
4	masculino : 50 anos ou mais	18	58	0.29	16.70
5	feminino : 18 a 24 anos	11	58	0.21	12.19
6	feminino : 25 a 34 anos	25	66	0.33	21.80
7	feminino : 35 a 49 anos	13	32	0.43	13.71
8	feminino : 50 anos ou mais	1	5	0.46	2.30

$$\hat{C} = 3.03 \rightarrow \text{p-valor} = 0.806$$

Teste Hosmer-Lemeshow no R

```
> glmtoolbox::hltest(m1Sex)
```

The Hosmer-Lemeshow goodness-of-fit test

Group	Size	Observed	Expected
1	105	13	11.808265
2	143	24	27.197188
3	58	11	12.191735
4	138	37	36.291221
5	58	18	16.703326
6	66	25	21.802812
7	32	13	13.708779
8	5	1	2.296674

Statistic = 3.02556

degrees of freedom = 6

p-value = 0.80563



FIOCRUZ

Outline

- 1 Revisitando o modelo logístico
- 2 Bondade de ajuste
- 3 Análise de resíduos**



FIOCRUZ

- Quais são as suposições?
 - Independência
- A análise de resíduos para dados binários não é tão natural quanto para outros tipos de variáveis.
- Como o desfecho assume somente dois valores, a visualização de padrões é mais difícil.
- Análises para procurar de pontos de alavanca e *outliers* continuam válidas.



- Quais são as suposições?
 - Independência
- A análise de resíduos para dados binários não é tão natural quanto para outros tipos de variáveis.
- Como o desfecho assume somente dois valores, a visualização de padrões é mais difícil.
- Análises para procurar de pontos de alavanca e *outliers* continuam válidas.



- Quais são as suposições?
 - Independência
- A análise de resíduos para dados binários não é tão natural quanto para outros tipos de variáveis.
- Como o desfecho assume somente dois valores, a visualização de padrões é mais difícil.
- Análises para procurar de pontos de alavanca e *outliers* continuam válidas.



- Quais são as suposições?
 - Independência
- A análise de resíduos para dados binários não é tão natural quanto para outros tipos de variáveis.
- Como o desfecho assume somente dois valores, a visualização de padrões é mais difícil.
- Análises para procurar de pontos de alavanca e *outliers* continuam válidas.



- Quais são as suposições?
 - Independência
- A análise de resíduos para dados binários não é tão natural quanto para outros tipos de variáveis.
- Como o desfecho assume somente dois valores, a visualização de padrões é mais difícil.
- Análises para procurar de pontos de alavanca e *outliers* continuam válidas.



- Leverage (pontos de alavanca): h_{ii} (*hatvalues(modelo)*)

$$H = X^T(X^T X)^{-1}X^T$$

Valores h_{ii} maiores que 2 ou 2 vezes p/n merecem uma olhada.

- Leave-one-out measures:

- DFFIT: Diferença nos ajustes: $\hat{y}_i - \hat{y}_{(i)}$
- DFBETs: Diferença no ajuste de cada regressor: $\hat{\beta}_j - \hat{\beta}_{j(i)}$
- DFBETs: Diferença no ajuste de cada regressor: $\hat{\beta}_j - \hat{\beta}_{j(i)}$



Outliers ou pontos influentes

- Leverage (pontos de alavanca): h_{ii} (*hatvalues(modelo)*)

$$H = X^T (X^T X)^{-1} X^T$$

Valores h_{ii} maiores que 2 ou 2 vezes p/n merecem uma olhada.

- Leave-one-out measures:
 - DFFIT: Diferença nos ajustes: $\hat{y}_i - \hat{y}_{i(-i)}$
 - DFBETA: Diferença no ajuste de cada coeficiente: $\hat{\beta}_k - \hat{\beta}_{k(-i)}$
 - Distância de Cook: Diferença no ajuste em todos coeficientes



FIOCRUZ

Outliers ou pontos influentes

- Leverage (pontos de alavanca): h_{ii} (*hatvalues(modelo)*)

$$H = X^T (X^T X)^{-1} X^T$$

Valores h_{ii} maiores que 2 ou 2 vezes p/n merecem uma olhada.

- Leave-one-out measures:
 - DFFIT: Diferença nos ajustes: $\hat{y}_i - \hat{y}_{i(-i)}$
 - DFBETA: Diferença no ajuste de cada coeficiente: $\hat{\beta}_k - \hat{\beta}_{k(-i)}$
 - Distância de Cook: Diferença no ajuste em todos coeficientes



FIOCRUZ

Outliers ou pontos influentes

- Leverage (pontos de alavanca): h_{ii} (*hatvalues(modelo)*)

$$H = X^T (X^T X)^{-1} X^T$$

Valores h_{ii} maiores que 2 ou 2 vezes p/n merecem uma olhada.

- Leave-one-out measures:
 - DFFIT: Diferença nos ajustes: $\hat{y}_i - \hat{y}_{i(-i)}$
 - DFBETA: Diferença no ajuste de cada coeficiente: $\hat{\beta}_k - \hat{\beta}_{k(-i)}$
 - Distância de Cook: Diferença no ajuste em todos coeficientes



FIOCRUZ

Outliers ou pontos influentes

- Leverage (pontos de alavanca): h_{ii} (*hatvalues(modelo)*)

$$H = X^T(X^T X)^{-1}X^T$$

Valores h_{ii} maiores que 2 ou 2 vezes p/n merecem uma olhada.

- Leave-one-out measures:
 - DFFIT: Diferença nos ajustes: $\hat{y}_i - \hat{y}_{i(-i)}$
 - DFBETA: Diferença no ajuste de cada coeficiente: $\hat{\beta}_k - \hat{\beta}_{k(-i)}$
 - Distância de Cook: Diferença no ajuste em todos coeficientes



FIOCRUZ

Outliers: Medidas de influência

```
> summary(influence.measures(m1Sex))
```

Potentially influential observations of

```
glm(formula = sifilis ~ sexo + faixaetaria, family = binomial(), data
```

	dfb.1_	dfb.sxfrm	dfb.fa3a	dfb.fa4a	dfb.faom	dffit	cov.r	cook.d	hat
103	-0.05	0.12	0.01	0.02	0.16	0.21	1.03_*	0.01	0.03_*
104	0.05	-0.11	-0.01	-0.02	-0.14	-0.19	1.03_*	0.01	0.03_*
143	0.05	-0.11	-0.01	-0.02	-0.14	-0.19	1.03_*	0.01	0.03_*
384	0.05	-0.11	-0.01	-0.02	-0.14	-0.19	1.03_*	0.01	0.03_*
560	0.05	-0.11	-0.01	-0.02	-0.14	-0.19	1.03_*	0.01	0.03_*



FIOCRUZ